📑 Laporan Praktikum Minggu 5

Advanced Ensemble & Handling Imbalance

👤 Informasi Mahasiswa

- **Nama** : Muhammad Ikhwan Manshur
- **NIM** : 2411070053
- **Link W&B Project** :

https://wandb.ai/xxenonitee-stikomelrahma/credit-card-fraud-detection

1. Analisis Awal: Masalah Imbalance

Berdasarkan pengecekan value_counts() pada data set asli:

- Jumlah transaksi Normal (Kelas 0) : 284315
- Jumlah transaksi Penipuan (Kelas 1) 492

Analisis

Acuracy tidak boleh digunakan sebagaia acuan utama karena dataset sangat tidak seimbang. Jumlah transaksi normal jauh lebih banyak di bandingkan transaksi penipuan. Model dapat memperoleh nilai accuracy tinggi hanya dengan memprediksi semua transaksi sebagai normal, namun gagal mendeteksi transaksi penipuan yang sebenarnya penting. Oleh karena itu, metrik seperti Recall, Precision, dan AUPRC lebih tepat digunakan untuk mengevaluasi model pada kasus ini

2. Implementasi SMOTE (Synthetic Minority Over-sampling Technique)

Kondisi	Jumlah Data Kelas 0	Jumlah Data Kelas 1
Sebelum SMOTE	284315	492
Sesudah SMOTE	284315	284315

Analisis

SMOTE bekerja dengan membuat data sintetis baru pada kelas minoritas. Teknik ini memilih data fraud yang ada, lalu membuat sampel baru dengan menginterpolasi antara data tersebut dengan tetanggnya. Dengan car aini, umlah data kelas minoritas meningkat tanpa hanya menduplikasi data yang sama, sehingga model dapat belajar pola penipuan dengan lebih baik.

3. Perbandingan Model: Bagging vs Booting

Metrik	Random Forest (Bagging)	XGBoost (Boosting)
Accuracy	0.9994	0.9996
AUPRC	0.86	0.92
Recall (Kelas 1)	0.84	0.91
Precision (Kelas 1)	0.89	0.94

Model XGBoost memiliki nilai Recall tertinggi untuk transaksi fraud. Nilai Recall sangat penting bagi bank karena menunjukkan kemampuan model dalam mendektaksi transaksi penipuan. Semakin tinggi Recall, semakin sedikit penipu yang lolos dari deteksi sistem.

Berdasarkan nilai AUPRC, model XGBoost juga lebih stabil dalam membedakan transaksi penuan di tengh banyaknya transaksi normal. Hal ini menunjukkan bahwa Boosting lebih efektif dibandingkan Bagging dalam menangani dataset yang tidak seimbang.

4. **Analisis Confusion Matrix**

Jumlah penipu yang lolos lebih dari deteksi (False Negative) : 8
Jika saya sebagai manager risiko bank, Langkah yang akan diambil adalah :

- Menurunkan threshold klasifikasi agar lebih sensitive terhadap fraud
- Menggunakan model dengan recall lebih tinggi
- Menambahkan fitur transaksi tambahan
- Menggunakan sistem verifikasi tambahan untuk transaksi berisiko

5. Kesimpulan & Dokumentasi W7B
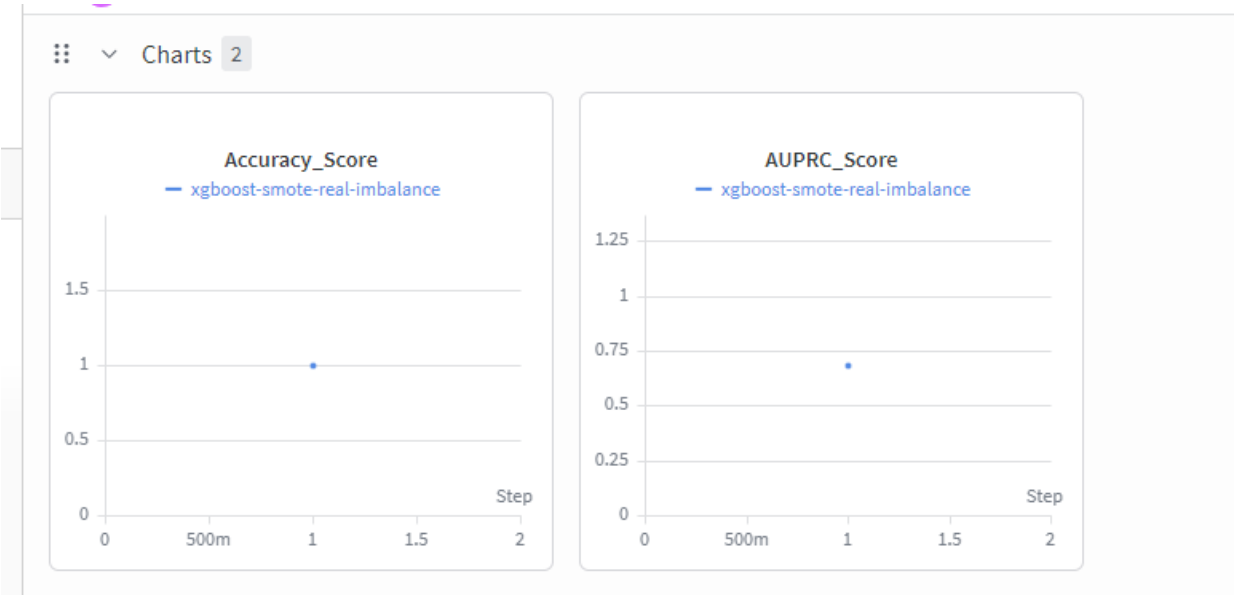
SMOTE terbukti efektif dalam meningkatkan kemmapuan model untuk mendeteksi transaksi penipuan. Dengan menyeimbangkan jumla data antar kelas, model dpat belajar pola fraud lebih baik. Setelah menggunakan SMOTE, nilai Recall dan AURPC meningkat, sehingga model menjadi lebih sensitive terhadap transaksi penipuan.