

Laporan Praktikum Minggu 5: Advanced Ensemble & Handling Imbalance

Nama : Salwa Hafizhah Yusuf
NIM : 2411070055
URL W&B Project : <https://wandb.ai/salwahafizhahyus-stikomelrahma/credit-card-fraud-detection?nw=nwusersalwahafizhahyus>
Link Pull Request GitHub : https://github.com/shy-coding24/Machine-Learning-Course-2026/tree/main/assignments/week-05/2411070055_Salwa%20Hafizhah%20Y

1. Analisis Awal: Masalah Imbalance

- Berapa jumlah transaksi Normal (kelas 0) : **49916**
- Berapa jumlah transaksi Normal (kelas 1) : **84**
- Mengapa metrik Accuracy tidak boleh digunakan sebagai acuan utama dalam dataset ini?

Dalam dataset yang sangat tidak seimbang (imbalance) seperti ini, di mana jumlah transaksi normal (kelas 0) jauh lebih banyak dibandingkan transaksi penipuan (kelas 1), metrik Accuracy tidak boleh digunakan sebagai acuan utama karena dapat sangat menyesatkan. Sebuah model dapat mencapai akurasi yang sangat tinggi (misalnya 99,83% seperti proporsi kelas 0) hanya dengan memprediksi semua transaksi sebagai 'Normal'. Meskipun akurasi tinggi, model tersebut akan sepenuhnya gagal mendeteksi penipuan (kelas 1), yang merupakan tujuan utama dari sistem deteksi penipuan. Oleh karena itu, metrik lain yang lebih sensitif terhadap performa kelas minoritas, seperti Recall, Precision, dan AUPRC (Area Under the Precision-Recall Curve), harus menjadi fokus utama.

2. Implementasi SMOTE (Synthetic Minority Over-sampling Technique)

Lampirkan Perbandingan Jumlah data sebelum dan sesudah SMOTE:

Kondisi	Jumlah Data Kelas 0	Jumlah Data Kelas 1
Sebelum SMOTE	39932	68
Sesudah SMOTE	39934	39934

Analisis: Jelaskan bagaimana SMOTE bekerja “menciptakan” data baru untuk menyeimbangkan kelas penipuan !

SMOTE (Synthetic Minority Over-sampling Technique) adalah metode untuk menyeimbangkan data dengan membuat sampel baru pada kelas minoritas, seperti transaksi penipuan.

1. SMOTE mencari beberapa data minoritas yang paling mirip (tetangga terdekat).
2. Lalu, SMOTE membuat data sintesis baru di antara data asli dan tetangga tersebut.
3. Proses diulang sampai jumlah data minoritas menjadi lebih seimbang dengan kelas mayoritas.

Dengan membuat data baru, bukan sekadar menyalin data lama, SMOTE membantu model lebih memahami pola kelas minoritas dan mengurangi risiko overfitting sehingga deteksi penipuan menjadi lebih akurat.

3. Perbandingan Model: Bagging vs Boosting

Metrik	Random Forest (Bagging)	XGBoost (Boosting)
Accuracy	0.9983	1.00
AUPRC	-0.0000 (sangat rendah)	0.6843
Recall (Kelas 1)	0.00	0.76
Precision (Kelas 1)	0.00	0.65

1. Model mana yang memiliki nilai recall tertinggi untuk transaksi Fraud (kelas 1)? Mengapa nilai recall sangat krusial bagi sebuah Bank?

Model XGBoost (Boosting) memiliki nilai Recall tertinggi untuk transaksi Fraud (Kelas 1), yaitu 0.76. Nilai Recall sangat krusial bagi sebuah Bank karena Recall mengukur kemampuan model untuk mengidentifikasi semua kasus positif (penipuan) yang sebenarnya dari seluruh kasus positif yang ada. Dengan kata lain, Recall menjawab pertanyaan: "Dari semua transaksi penipuan yang benar-benar terjadi, berapa banyak yang berhasil dideteksi oleh model?" Bagi bank, kegagalan mendeteksi transaksi penipuan dapat mengakibatkan kerugian finansial yang signifikan, merusak kepercayaan pelanggan, dan menimbulkan masalah hukum. Oleh karena itu, meminimalkan False Negatives (penipuan yang tidak terdeteksi) adalah prioritas utama, dan Recall yang tinggi menunjukkan keberhasilan dalam mencapai tujuan ini.

2. Berdasarkan hasil AUPRC, model mana yang paling stabil dalam membedakan penipu ditengah ribuan transaksi normal?

Berdasarkan hasil AUPRC, model XGBoost (Boosting) dengan nilai 0.6843 adalah yang paling stabil dalam membedakan penipu. AUPRC adalah metrik yang sangat relevan untuk dataset tidak seimbang karena ia berfokus pada performa model pada kelas minoritas (positif) dan kurang terpengaruh oleh kelas mayoritas. Nilai AUPRC untuk Random Forest sangat rendah (mendekati 0), yang mengindikasikan bahwa model tersebut (seperti yang diimplementasikan dan dievaluasi) hampir tidak memiliki kemampuan untuk membedakan transaksi penipuan dari transaksi normal. XGBoost, dengan AUPRC yang jauh lebih tinggi, menunjukkan kemampuan yang lebih baik dan lebih stabil dalam membuat prediksi yang akurat untuk kelas penipuan, bahkan di tengah banyak transaksi normal.

4. Analisis Confusion Matrix

- Berapa jumlah penipu yang berhasil “lolos” dari deteksi model Anda? **4 transaksi**
- Jika Anda adalah manajer risiko bank, Langkah apa yang akan anda ambil untuk meminimalkan angka tersebut?

Jika saya menjadi manajer risiko bank, 4 transaksi penipuan yang lolos deteksi tetap harus ditangani serius. Untuk mengurangi False Negatives (FN), langkah yang dapat dilakukan adalah:

1. Menyesuaikan ambang batas klasifikasi agar model lebih sensitif dalam mendeteksi penipuan, meskipun risiko False Positives bisa meningkat.
2. Menggabungkan XGBoost dengan model lain agar deteksi penipuan lebih akurat.
3. Membuat fitur baru yang lebih relevan untuk membedakan transaksi normal dan penipuan.
4. Menganalisis transaksi FN yang lolos untuk menemukan pola yang belum dipelajari model.
5. Menambah data penipuan yang valid agar model dapat belajar lebih baik dan meningkatkan akurasi deteksi.

5. Kesimpulan & Dokumentasi W&B

Berdasarkan eksperimen ini, SMOTE terbukti sangat efektif dalam meningkatkan kemampuan model Boosting (XGBoost) untuk mendeteksi penipuan pada dataset yang sangat tidak seimbang. Sebelum SMOTE, model (terutama Random Forest) mungkin cenderung mengabaikan kelas minoritas karena dominasi kelas mayoritas. Dengan menyeimbangkan dataset melalui SMOTE, model XGBoost mampu belajar pola karakteristik penipuan dengan lebih baik, yang ditunjukkan oleh nilai Recall (0.76) dan AUPRC (0.6843) yang jauh lebih tinggi dibandingkan model Random Forest yang setelah SMOTE pun masih menunjukkan performa yang sangat buruk pada kelas penipuan (Recall 0.00, AUPRC ~0.00). Ini menegaskan bahwa SMOTE membantu mengatasi masalah bias model terhadap kelas mayoritas, memungkinkan model untuk menjadi lebih sensitif dan akurat dalam mengidentifikasi kasus penipuan yang langka.



```
runs.summary["raw_sample"]
```

	V1	V2	V3	V4	V5	V6	V7	V8	V9	V10	V11	V12	V13
1	-18.527	8.585	-18.85	9.508	-13.794	-2.832	-18.702	7.517	-8.507	-14.11	5.299	-10.834	1.871
2	0.3398	-2.744	-0.1341	-1.388	-1.451	1.018	-0.5244	0.2241	0.8997	-0.565	-0.08787	0.9794	0.07888
3	1.4	-0.5907	0.1888	-1.03	-0.5398	0.04044	-0.7128	0.002299	-0.9717	0.7568	0.5438	0.1125	1.075
4	-0.4321	1.648	-1.889	-0.3495	0.7858	-0.8306	0.277	0.588	-0.4847	-1.377	-1.328	0.2238	1.133
5	2.014	-0.1374	-1.018	0.3273	-0.1822	-0.9568	0.04324	-0.1807	0.3832	0.2595	0.9422	0.85	-0.8182
6	-0.8413	-0.0573	1.49	-1.888	-1.151	0.28	-1.391	-2.334	1.189	-2.084	0.4804	0.4737	-2.192

← < 1 - 6 of 800 > →

Export as CSV Columns... Reset table