Laporan Praktikum Minggu 5: Advanced Ensemble & Handling Imbalance

Informasi Mahasiswa:

- **Nama:** Mush'ab Abdurrahman Fathin
- **NIM:** 2411070062
- **Link W&B Project:** https://wandb.ai/mushab-a-fathin-stikomelrahma/credit-card-fraud-detection?nw=nwusermushabafathin

1. Analisis Awal: Masalah Imbalance

Berdasarkan pengecekan `value_counts()` pada dataset asli:

- Berapa jumlah transaksi Normal (Kelas 0)?
- Berapa jumlah transaksi Penipuan (Kelas 1)?
- **Analisis:** Mengapa metrik **"Accuracy"** tidak boleh digunakan sebagai acuan utama dalam dataset ini?

Jawaban:

Pada dataset asli yang dipakai di notebook, jumlah transaksi Normal (Kelas 0) adalah 49.917 dan transaksi Penipuan/Fraud (Kelas 1) adalah 83. Ini menunjukkan bahwa data sangat tidak seimbang karena transaksi fraud jumlahnya sangat kecil dibanding transaksi normal. Karena kondisi ini, metrik Accuracy tidak boleh dipakai sebagai acuan utama. Alasannya, model bisa saja menebak hampir semua transaksi sebagai normal lalu tetap mendapat nilai Accuracy yang sangat tinggi, padahal sebenarnya gagal menemukan fraud. Pada kasus seperti ini, metrik yang lebih penting adalah Recall, Precision, dan terutama AUPRC karena metrik-metrik tersebut lebih fokus melihat kemampuan model dalam mengenali kelas fraud yang langka.

Detail tambahan dari hasil notebook: dataset berasal dari OpenML ID 1597 dan untuk mempercepat praktikum digunakan sampel 50.000 transaksi. Dari jumlah itu, hanya sekitar 0,17% yang termasuk fraud.

2. Implementasi SMOTE (Synthetic Minority Over-sampling Technique)

Lampirkan perbandingan jumlah data sebelum dan sesudah SMOTE:

Kondisi	Jumlah Data Kelas 0	Jumlah Data Kelas 1
Sebelum SMOTE (data latih)	39.934	66
Sesudah SMOTE (data latih)	39.934	39.934

Analisis: Jelaskan bagaimana SMOTE bekerja "menciptakan" data baru untuk menyeimbangkan kelas penipuan.

SMOTE bekerja dengan membuat data sintetis baru untuk kelas minoritas, yaitu fraud. Data baru ini bukan hasil menyalin transaksi lama, tetapi dibuat berdasarkan kemiripan beberapa contoh fraud yang berdekatan. Dengan cara ini, model mendapat lebih banyak variasi pola fraud untuk dipelajari. Pada hasil praktikum ini, data latih yang awalnya 39.934 transaksi normal dan hanya 66 transaksi fraud berubah menjadi seimbang, yaitu 39.934 banding 39.934 setelah SMOTE.

Detail tambahan dari notebook: SMOTE diterapkan hanya pada data latih, sedangkan data uji tetap dibiarkan timpang agar evaluasi model tetap merefleksikan kondisi dunia nyata.

3. Perbandingan Model: Bagging vs Boosting

Isi tabel perbandingan performa pada **“Data Test”**:

Metrik	Random Forest (Bagging)	XGBoost (Boosting)
Accuracy	≈ 0,999	0,9989
AUPRC	≈ 0,676	0,6843
Recall (Kelas 1)	≈ 0,69	0,76
Precision (Kelas 1)	≈ 0,86	0,65

Pertanyaan Kritis:

1. Model mana yang memiliki nilai **“Recall”** tertinggi untuk transaksi Fraud (Kelas 1)? Mengapa nilai Recall sangat krusial bagi sebuah Bank?

2. Berdasarkan hasil **“AUPRC”**, model mana yang paling stabil dalam membedakan penipu di tengah ribuan transaksi normal?

Jawaban:

Model yang memiliki nilai Recall lebih tinggi untuk transaksi Fraud (Kelas 1) adalah XGBoost, yaitu sekitar 0,76, sedangkan Random Forest sekitar 0,69. Nilai Recall sangat penting bagi bank karena Recall menunjukkan seberapa banyak transaksi fraud yang berhasil ditemukan. Jika Recall rendah, akan ada lebih banyak penipu yang lolos tanpa terdeteksi. Berdasarkan nilai AUPRC, XGBoost juga sedikit lebih baik daripada Random Forest, sehingga dapat dikatakan lebih stabil dalam membedakan penipu di tengah ribuan transaksi normal.

Detail tambahan dari hasil dashboard W&B: Random Forest tampak memiliki Precision lebih tinggi (sekitar 0,86). Ini berarti saat Random Forest menandai suatu transaksi sebagai fraud, tebakan itu cenderung lebih bersih. Namun dalam konteks perbankan, menangkap fraud sebanyak mungkin biasanya lebih penting daripada sekadar mengurangi alarm palsu, sehingga Recall tetap menjadi fokus utama.

4. Analisis Confusion Matrix

Lihat kuadran **“False Negative”** (Asli Fraud, tapi ditebak Normal) pada model terbaik Anda:

- Berapa jumlah penipu yang berhasil "lolos" dari deteksi model Anda?
- Jika Anda adalah manajer risiko bank, langkah apa yang akan Anda ambil untuk meminimalkan angka tersebut?
  Jawaban: Pada model terbaik yang digunakan, jumlah False Negative adalah 4. Artinya ada 4 transaksi fraud yang masih lolos dan diprediksi sebagai transaksi normal. Jika saya menjadi manajer risiko bank, saya akan mencoba menurunkan threshold prediksi, melakukan tuning parameter, menambah aturan review manual pada transaksi berisiko tinggi, dan menambah fitur perilaku transaksi agar sistem menjadi lebih sensitif terhadap fraud.
  Detail menarik dari hasil notebook: confusion matrix XGBoost + SMOTE menunjukkan TN = 9.976, FP = 7, FN = 4, dan TP = 13. Jadi dari total 17 transaksi fraud di data uji, model berhasil menangkap 13 transaksi fraud.

5. Kesimpulan & Dokumentasi W&B

- Apa kesimpulan Anda mengenai efektivitas SMOTE dalam meningkatkan kemampuan model mendeteksi penipuan?
- Lampirkan screenshot grafik AUPRC dari dashboard W&B Anda.
  Kesimpulan: SMOTE terbukti cukup efektif untuk meningkatkan kemampuan model dalam mendeteksi penipuan. Setelah data latih diseimbangkan, model terbaik mampu mengenali 13 dari 17 transaksi fraud pada data uji dengan Recall sekitar 0,76 dan AUPRC 0,6843. Ini menunjukkan bahwa SMOTE membantu model lebih peka terhadap kelas fraud yang sangat sedikit, walaupun hasilnya belum sempurna karena masih ada 4 fraud yang lolos.
  Detail tambahan dari file notebook: selain evaluasi model, praktikum ini juga mencatat sampel data ke W&B Tables dan membuat proof of concept sederhana menggunakan Gradio. Jadi, hasil model tidak hanya berhenti pada angka, tetapi juga bisa dilihat dalam bentuk dashboard dan dicoba pada antarmuka mini.

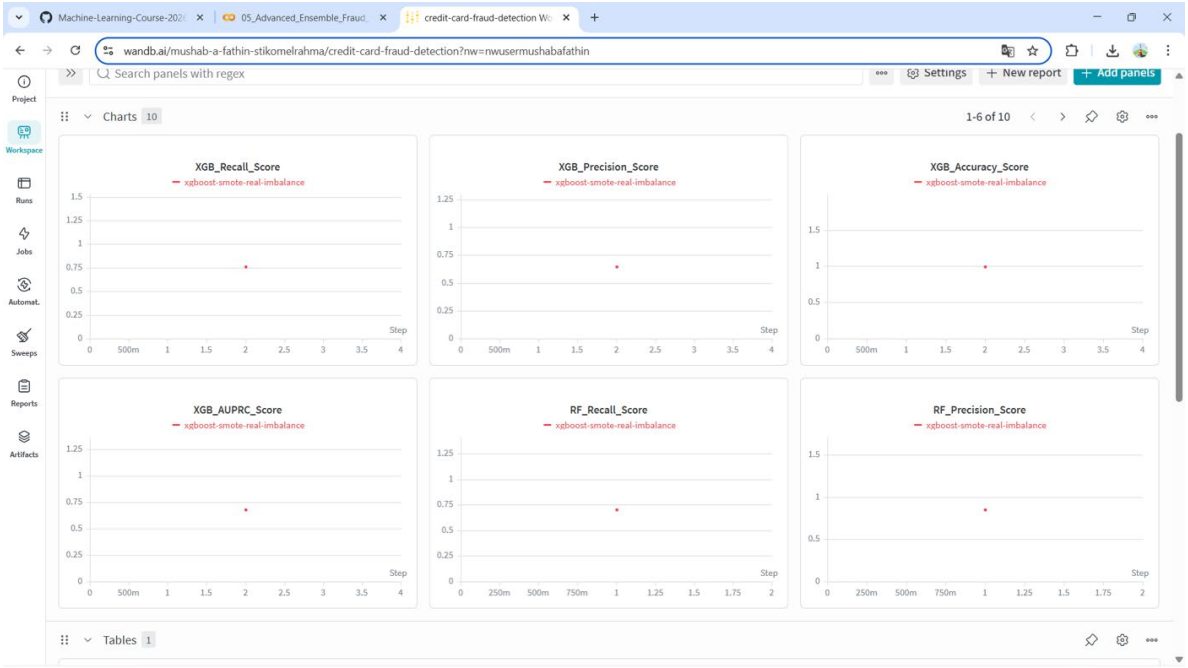
Machine-Learning-Course-2024
05_Advanced_Ensemble_Fraud_
credit-card-fraud-detection Wo
wandb.ai/mushab-a-fathin-stikomelrahma/credit-card-fraud-detection?nw=nwusermushabafathin
Search panels with regex
Settings
New report
Add panels
Project
Workspace
Runs
Jobs
Automat.
Sweeps
Reports
Artifacts
Charts 10
1-6 of 10
XGB_Recall_Score
xgboost-smote-real-imbalance
XGB_Precision_Score
xgboost-smote-real-imbalance
XGB_Accuracy_Score
xgboost-smote-real-imbalance
XGB_AUPRC_Score
xgboost-smote-real-imbalance
RF_Recall_Score
xgboost-smote-real-imbalance
RF_Precision_Score
xgboost-smote-real-imbalance
Step
Tables 1

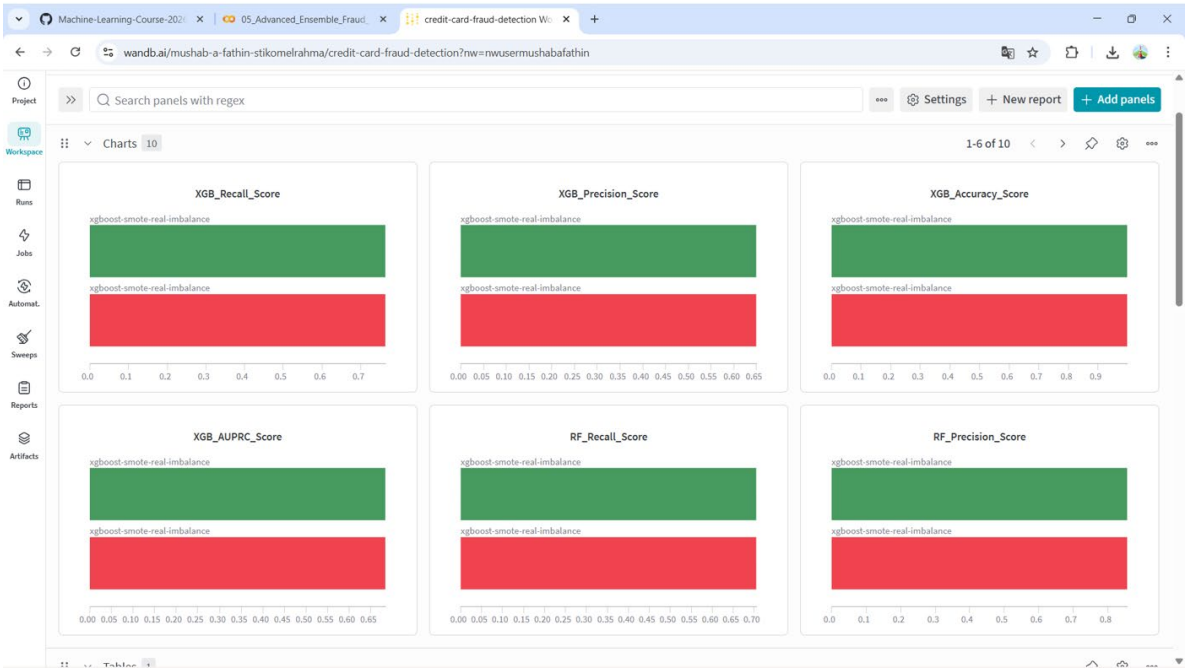
Machine-Learning-Course-2024
05_Advanced_Ensemble_Fraud_
credit-card-fraud-detection Wo
wandb.ai/mushab-a-fathin-stikomelrahma/credit-card-fraud-detection?nw=nwusermushabafathin
Search panels with regex
Settings
New report
Add panels
Project
Workspace
Runs
Jobs
Automat.
Sweeps
Reports
Artifacts
Charts 10
1-6 of 10
XGB_Recall_Score
XGB_Precision_Score
XGB_Accuracy_Score
XGB_AUPRC_Score
RF_Recall_Score
RF_Precision_Score
xgboost-smote-real-imbalance