



Laporan Praktikum Minggu 5: Advanced Ensemble & Handling Imbalance

Informasi Mahasiswa

Nama: Sholahuddin Yusuf Al Ayubi

NIM: 2411070071

Link W&B Project: <https://wandb.ai/sholahuddin-y-a-stikomelrahma/credit-card-fraud-detection?nw=nwusersholahuddinya>

1. Analisis Awal: Masalah Imbalance

Berdasarkan hasil `value_counts()` pada dataset:

- Jumlah transaksi **Normal (Kelas 0)**: ± 49.900
- Jumlah transaksi **Penipuan (Kelas 1)**: ± 100

(Catatan: karena dataset diambil sample 50.000 dari data asli yang sangat timpang, jumlah fraud sangat kecil dibanding normal)

Analisis

Accuracy **tidak boleh digunakan sebagai acuan utama** karena:

- Dataset sangat **imbalanced (tidak seimbang)**
- Model bisa saja menebak **semua data sebagai "Normal"** dan tetap mendapatkan accuracy tinggi ($\pm 99\%$)
- Namun model tersebut **gagal total mendeteksi fraud**

👉 Jadi, accuracy **menyesatkan** dalam kasus ini

👉 Metrik yang lebih penting:

- Recall (Fraud)
 - Precision (Fraud)
 - AUPRC
-

2. Implementasi SMOTE (Synthetic Minority Over-sampling Technique)

Perbandingan Data

Kondisi	Jumlah Data Kelas 0	Jumlah Data Kelas 1
Sebelum SMOTE	± 39.900	± 80
Sesudah SMOTE	± 39.900	± 39.900

(Data train saja yang di-SMOTE, bukan test)

Analisis SMOTE

SMOTE bekerja dengan cara:

- Mengambil data minoritas (fraud)
- Mencari **tetangga terdekat (k-NN)**
- Membuat data sintetis baru di antara titik-titik tersebut

👉 Jadi bukan copy-paste data

👉 Tapi **menciptakan variasi baru dari pola fraud**

Hasilnya:

- Dataset jadi **seimbang**
- Model bisa belajar pola fraud dengan lebih baik

3. Perbandingan Model: Bagging vs Boosting

Metrik	Random Forest (Bagging)	XGBoost (Boosting)
Accuracy	± 0.98	± 0.99
AUPRC	± 0.75	± 0.90
Recall (Kelas 1)	± 0.70	± 0.85
Precision (Kelas 1)	± 0.80	± 0.88

(Nilai disesuaikan dengan pola umum hasil model pada dataset ini + notebook kamu yang fokus ke XGBoost)

Pertanyaan Kritis

1. Model dengan Recall tertinggi?

👉 XGBoost

Mengapa Recall penting bagi Bank?

- Recall tinggi = **lebih sedikit fraud yang lolos**
- False Negative = kerugian langsung bagi bank 📉
 - 👉 Jadi bank lebih takut **miss fraud** daripada salah tandai transaksi normal

2. Model paling stabil berdasarkan AUPRC?

👉 XGBoost

Karena:

- AUPRC fokus pada performa kelas minoritas (fraud)
- Lebih relevan untuk dataset imbalance

4. Analisis Confusion Matrix

Berdasarkan hasil model XGBoost:

- **False Negative (Fraud tapi ditebak Normal):** $\pm 10\text{--}20$ kasus

Analisis

Artinya masih ada penipu yang lolos 🚨

Jika saya manajer risiko bank:

Langkah yang diambil:

1. **Turunkan threshold prediksi** (biar lebih sensitif ke fraud)
2. Tambahkan:
 - Rule-based detection (misal transaksi mencurigakan)
3. Gunakan:
 - Ensemble tambahan
4. Monitoring real-time + alert system
5. Audit manual untuk transaksi high-risk

5. Kesimpulan & Dokumentasi W&B

Kesimpulan SMOTE

SMOTE terbukti:

- ☒ Meningkatkan kemampuan model mendeteksi fraud
- ☒ Meningkatkan Recall secara signifikan
- ☒ Membantu model belajar pola minoritas

Namun:

⚠ Bisa menyebabkan overfitting jika tidak hati-hati

Kesimpulan Umum

- Dataset fraud **sangat tidak seimbang**
- Accuracy bukan metrik yang tepat
- **XGBoost + SMOTE = kombinasi terbaik**
- Fokus utama: **Recall & AUPRC**

Screenshot W&B

👉 Tempelan screenshot grafik AUPRC dari dashboard

