Laporan Praktikum Minggu 5: Advanced Ensemble & Handling Imbalance

Nama : Raki Raihan

NIM : 2411070095

Link W&B Project : https://wandb.ai/han-dev321-stikomelrahma/credit-card-fraud-detection

---

1. Analisis Awal: Masalah Ketidakseimbangan

Tes value_counts () pada dataset asli:

- **Jumlah transaksi Normal (Kelas 0) : 49917** transaksi
- **Jumlah transaksi Penipuan (Kelas 1): 83** transaksi
- **Analisis :**
  karena model akan menjadi "malas" apabila tanpa penangan khusus, sehingga tidak dapat digunakan sebagai acuan utama dalam kasus ini. Jika model memprediksi **semua** transaksi "**Normal**" (kelas 0), maka akurasi model tersebut: "***Accuracy* = 49917/50000*100 = 99,83%**"
  Sehingga model tersebut **gagal mendeteksi satupun** (0%) transaksi penipuan, meskipun akurasi 99,83%

---

2. Implementasi SMOTE (*Synthetic Minority Over-Sampling Technique*)

Perbandingan data sebelum dan sedudah SMOTE:

Kondisi	Jumlah Data Kelas 0	Jumlah Data Kelas 1
Sebelum SMOTE	**40000** Transaksi (Data Training)	**66** Transaksi (Data Training)
Sesudah SMOTE	**40000** Transaksi (Data Training)	**40000** Transaksi (Data Training)

- **Analisis :**
  SMOTE → Teknik yang jauh lebih cerdas daripada sekedar menyalin ulang data yang sudah ada (random oversampling). Cara kerjanya:

1. **Mencari tetangga terdekat (*K-Nearest Neighbors*):** melihat satu titik data fraud, lalu mencari titik data fraud lainnya yang paling dekat posisinya dalam ruang fitur.
2. **Menarik Garis Imajiner:** menarik garis lulus yang menghubungkan titik asal dengan tetangga terdekat.
3. **Menciptakan Titik Sintetis:** kemudian meletakkan titik data baru secara acak di sepanjang garis tsb

---

3. Perbandingan Model: Bagging vs Boosting

Table perbandingan kinerja pada **uji data**:

Metrik	Hutang Acak (Bagging)	XGBoost (Boosting)
Ketepatan	~ 1,00 (99,8%)	**1,00 (100%)**
AUPRC	~ 0,6200	**0,6843**
• **Ingat kembali (Kelas 1)**	~ 0,70 (70%)	**0,76 (76%)**
Presisi (Kelas 1)	~ 0,60 (60%)	**0,65 (65%)**

Pertanyaan Kritis:

- **- Recall** mana dengan **nilai tertinggi** untuk transaksi **Fraud ? :** Berdasarkan hasil training, **Recall** pada **model XGBoost**-lah yang memiliki **nilai tinggi** sekitar **0,76 / 76% -** mengapa **recall** penting untuk sebuah **bank? :** Karena menjawab pertanyaan dari "berapa banyak yang berhasil sistem deteksi?" yang berupa:
  - **Kerugian Finansial:** karena setiap transaksi **fraud** yang **gagal dideteksi = Kerugian langsung** bagi **bank** atau **nasabah.**
  - **Keamanan Sistem :** karena meloloskan satu transaksi penipuan besar bisa merusak reputasi dan asset, sehingga lebih baik salah mencurigai transaksi normal yang bisa dikonfirmasi ulang.

- **Hasil AUPRC, Model paling stabil dalam membedakan penipu di ribuan transaksi normal? :** Jatuh pada **model "XGBoost"** dengan skor **"0,6843"** lebih tinggi disbanding dengan algoritma **Bagging biasa,** karena **XGBoost** terbukti lebih stabil dan "cerdas" dalam memisahkan antara penipu yang sangat sedikit dengan ribuan nasabah normal tanpa harus menghasilkan terlalu banyak alarm palsu

---

4. Analisis Matriks Kebingungan

Kuadran **False Negative** (Asli Fraud, tapi normal) pada model terbaik saya:

- Jumlah **penipu** yang berhasil **"lolos"** dari **deteksi model saya: "4** Transaksi Penipuan"
- Apabila saya manajer risiko bank, langkah yang saya ambil untuk meminimalkan angka yaitu: saya akan mengambil langkah tersebut:
    1. **Optimasi Bobot Model** **:** menambahkan parameter "**scale_pos_weight**" pada **XGBoost** guna memberi penalty 10x lebih besar jika model gagal mendeteksi satu transaksi fraud
    2. **Sistem Verifikasi Real-time (2FA)** **:** transaksi yang dicurigai (skor menengah), sistem akan mengirimkan **OTP** ke aplikasi nasabah sebelum diproses

---

5. Kesimpulan & Dokumentasi W&B

- Kesimpulan saya mengenai **Efektivitas SMOTE:**
    1. **Penyelamat dari "*Accuracy Paradox*":** karena apabila tanpa **SMOTE**, model cenderung mengabaikan kelas minoritas sebab jumlahnya yang terlalu sedikit.
    2. **Peningkatan Recall Secara Signifikan:** karena **SMOTE** mempeluas batas keputusan model, sehingga model menjadi jauh lebih sensitive.
    3. **Keseimbangan Model:** karena **SMOTE** membantu menjaga nilai **AUPRC tetap stabil**. **Bukti** data sintetis hasil **SMOTE** tidak membuat **model *overfit***, tapi benar-benar memahami polanya (penipuan dunia nyata).

- **Screenshot grafik AUPRC by W&B:**