

Laporan UTS Machine Learning 2026

Informasi Mahasiswa:

Nama	: Siti Yolanda Hareniza
NIM	: 2411070032
Project Link (W&B)	: https://wandb.ai/sitiyolandahareniza-stikomelrahma/uts-fraud-detection
Pull Request Link (Github)	: https://github.com/yolanland/Machine-Learning-Course-2026/tree/main/assignments/week-08/2411070032_Siti%20Yolanda%20Hareniza

1. Problem Statement & Dataset

- Dataset apa yang Anda pilih?
- Apa masalah yang ingin diselesaikan (Klasifikasi/Regresi)?
- Mengapa masalah ini penting untuk diselesaikan dengan ML?

Jawaban: Dataset yang digunakan adalah Credit Card Fraud Detection.

Masalah yang diselesaikan adalah klasifikasi, yaitu memprediksi apakah suatu transaksi termasuk normal (0) atau penipuan (1).

Masalah ini penting karena penipuan transaksi dapat menyebabkan kerugian finansial yang besar. Dengan Machine Learning, sistem dapat membantu mendeteksi pola transaksi mencurigakan secara otomatis dan lebih cepat, sehingga dapat mengurangi risiko kerugian.

2. Exploratory Data Analysis (EDA)

- Ceritakan temuan menarik dari data Anda.
- Apakah ada korelasi kuat? Apakah ada data yang timpang (imbalanced)?
- Tampilkan visualisasi utama Anda.


Jawaban : Berdasarkan hasil eksplorasi data, ditemukan bahwa dataset memiliki jumlah fitur yang cukup banyak dan seluruh fitur sudah dalam bentuk numerik.

Distribusi kelas menunjukkan bahwa data sangat tidak seimbang (imbalanced), di mana:

- Kelas 0 (Normal) jauh lebih banyak
- Kelas 1 (Fraud) sangat sedikit

Hal ini terlihat pada grafik visualisasi yang menunjukkan dominasi kelas normal.

Kondisi ini menjadi tantangan karena model berpotensi bias terhadap kelas mayoritas dan sulit mendeteksi transaksi penipuan.



Gambar 1. Grafik Visualisasi Imbalance

3. Preprocessing & Feature Engineering

- Langkah apa saja yang Anda lakukan (Handling missing values, Scaling, Encoding)?
- Jika data imbalanced, bagaimana Anda menanganinya? (SMOTE/Weighting)

Jawaban : Langkah preprocessing yang dilakukan meliputi:

- Mengubah tipe data target menjadi integer
- Memisahkan fitur (X) dan target (y)

- Membagi data menjadi training dan testing (70:30)
- Tidak dilakukan encoding karena data sudah numerik
- Tidak ditemukan missing values sehingga tidak perlu dilakukan penanganan khusus

Untuk mengatasi ketidakseimbangan data, digunakan teknik **SMOTE (Synthetic Minority Over-sampling Technique)** yang berfungsi untuk menyeimbangkan jumlah data antara kelas normal dan fraud dengan membuat data sintetis pada kelas minoritas.

4.Eksperimen Model (Battle of Algorithms)

Bandingkan performa minimal 3 model yang Anda pilih (Misal: MLP vs XGBoost vs Logistic Regression).

Jawaban : Tiga model yang digunakan dalam eksperimen adalah:


- Logistic Regression
- Random Forest
- XGBoost

Model	Accuracy/RMSE	Precision	AUPRC/Recall	F1-Score
Logistic Regression	0.979	0.068	0.919	0.126
Random Forest	0.999	0.855	0.867	0.861
XGBoost	0.999	0.781	0.889 / 0.867	0.822

5. Analisis Hasil & W&B Tracking

- Berdasarkan dashboard W&B, model mana yang paling unggul?
- Analisis Confusion Matrix: Bagaimana model Anda menangani False Positive/Negative?
- Fitur apa yang paling berpengaruh (Feature Importance)?

Jawaban: Berdasarkan hasil eksperimen dan dashboard Weights & Biases (W&B), model **XGBoost** menunjukkan performa terbaik dibandingkan model lainnya, terutama pada metrik **Recall** dan **AUPRC**.



Gambar 2. Dashboard Credit Fraud Detection W&B

Pada dataset imbalanced, metrik accuracy tidak cukup representatif karena model dapat mencapai nilai tinggi tanpa benar-benar mendeteksi fraud. Oleh karena itu, metrik recall dan AUPRC lebih digunakan sebagai acuan utama.


Analisis Confusion Matrix:

- **False Positive (FP):** Transaksi normal yang dianggap fraud
- **False Negative (FN):** Transaksi fraud yang tidak terdeteksi

Kesalahan False Negative lebih berbahaya karena penipuan dapat lolos dari sistem.

- **Feature Importance:**

Berdasarkan grafik feature importance, beberapa fitur memiliki pengaruh lebih besar dalam menentukan apakah suatu transaksi termasuk fraud, sehingga model dapat fokus pada pola tertentu dalam data.



Gambar 3. Grafik Feature Importance

6. Kesimpulan & Rekomendasi

- Apakah model Anda sudah siap digunakan di dunia nyata?
- Apa keterbatasan model Anda saat ini?

Jawaban: Model yang dibangun sudah cukup baik dalam mendeteksi transaksi penipuan, terutama setelah menggunakan SMOTE untuk mengatasi ketidakseimbangan data.

Namun, model belum sepenuhnya siap digunakan di dunia nyata karena masih terdapat kesalahan prediksi, terutama pada False Negative yang berpotensi menyebabkan kerugian.

Untuk pengembangan selanjutnya, dapat dilakukan:

- Penyesuaian threshold prediksi
- Penambahan fitur baru
- Penggunaan teknik tuning hyperparameter untuk meningkatkan performa model