Laporan Praktikum Minggu 5: Advanced Ensemble & Handling Imbalance

Informasi Mahasiswa:

- **Nama:** Nisa Agustin
- **NIM:** 2411070040
- **Link W&B Project:** https://wandb.ai/nisaagustin083-stikomelrahma/credit-card-fraud-detection

---

1. Analisis Awal: Masalah Imbalance

Berdasarkan pengecekan value_counts() pada dataset asli:

- Berapa jumlah transaksi Normal (Kelas 0)?
- Berapa jumlah transaksi Penipuan (Kelas 1)?
- **Analisis:** Mengapa metrik **Accuracy** tidak boleh digunakan sebagai acuan utama dalam dataset ini?

Jawaban: Berdasarkan hasil value_counts() pada dataset:

- Jumlah transaksi **Normal (Kelas 0)**: **49,917**
- Jumlah transaksi **Penipuan (Kelas 1)**: **83**

  Analisis :

  Dataset ini termasuk **sangat tidak seimbang (imbalanced)** karena jumlah transaksi normal jauh lebih banyak dibandingkan transaksi penipuan. Proporsi kelas normal mencapai sekitar **99.8%**, sedangkan penipuan hanya sekitar **0.16%**.
  Metrik **accuracy tidak dapat dijadikan acuan utama**, karena dapat memberikan hasil yang menyesatkan. Misalnya, jika model selalu memprediksi semua data sebagai kelas normal, maka model tetap bisa memperoleh accuracy tinggi (sekitar 99%), tetapi gagal mendeteksi transaksi penipuan sama sekali.
  Oleh karena itu, metrik lain seperti **precision, recall, dan F1-score** lebih penting digunakan untuk mengevaluasi performa model, terutama dalam mendeteksi kelas minoritas (penipuan).

---

2. Implementasi SMOTE (Synthetic Minority Over-sampling Technique)

Lampirkan perbandingan jumlah data sebelum dan sesudah SMOTE:

Kondisi	Jumlah Data Kelas 0	Jumlah Data Kelas 1
Sebelum SMOTE	49,917	83
Sesudah SMOTE	49,917	49,917

Analisis: SMOTE bekerja dengan cara membuat data sintetis untuk kelas minoritas (penipuan) dengan menggunakan pendekatan nearest neighbors. Data baru dihasilkan dengan menginterpolasi nilai antara satu data minoritas dengan data tetangganya.

Dengan teknik ini, data penipuan yang awalnya sangat sedikit ditambah hingga jumlahnya seimbang dengan kelas normal. Hal ini membantu model machine learning agar tidak bias terhadap kelas mayoritas dan mampu mengenali pola penipuan dengan lebih baik.

---

3. Perbandingan Model: Bagging vs Boosting

Isi tabel perbandingan performa pada **Data Test**:

Metrik	Random Forest (Bagging)	XGBoost (Boosting)
Accuracy	0.9993	1.00
AUPRC	0.6748	0.6843
Recall (Kelas 1)	0.65	0.76
Precision (Kelas 1)	0.92	0.65

Pertanyaan Kritis:

1. Model mana yang memiliki nilai **Recall** tertinggi untuk transaksi Fraud (Kelas 1)? Mengapa nilai Recall sangat krusial bagi sebuah Bank?
2. Berdasarkan hasil **AUPRC**, model mana yang paling stabil dalam membedakan penipu di tengah ribuan transaksi normal?

Jawaban:

1. **Model dengan Recall tertinggi untuk Fraud (Kelas 1)** adalah **XGBoost** dengan nilai recall sebesar **0.76**, dibandingkan Random Forest sebesar **0.65**.

Recall sangat krusial bagi bank karena menunjukkan kemampuan model dalam **mendeteksi transaksi penipuan secara benar**

2. Berdasarkan nilai **AUPRC**, model **XGBoost (0.6843)** sedikit lebih unggul dibandingkan Random Forest (0.6748).
   AUPRC merupakan metrik yang penting untuk dataset tidak seimbang karena berfokus pada kemampuan model dalam membedakan kelas positif (fraud). Nilai AUPRC yang lebih tinggi menunjukkan bahwa model lebih **stabil dan konsisten** dalam mendeteksi penipuan di tengah banyaknya transaksi normal.

---

4. Analisis Confusion Matrix

Lihat kuadran **False Negative** (Asli Fraud, tapi ditebak Normal) pada model terbaik Anda:

- Berapa jumlah penipu yang berhasil "lolos" dari deteksi model Anda?

  Jumlah penipu yang berhasil “lolos” dari deteksi model adalah sekitar **4 transaksi** (False Negative).

- Jika Anda adalah manajer risiko bank, langkah apa yang akan Anda ambil untuk meminimalkan angka tersebut?

  Jika saya adalah manajer risiko bank, langkah yang dapat diambil untuk meminimalkan angka tersebut adalah:

1. **Meningkatkan recall model**, misalnya dengan tuning parameter atau menyesuaikan threshold prediksi
2. Menggunakan **threshold probabilitas yang lebih rendah** agar lebih sensitif terhadap fraud
3. Mengkombinasikan model dengan **rule-based system** (misalnya transaksi mencurigakan langsung ditandai)
4. Melakukan **monitoring dan retraining model secara berkala** dengan data terbaru

---

5. Kesimpulan & Dokumentasi W&B

- Apa kesimpulan Anda mengenai efektivitas SMOTE dalam meningkatkan kemampuan model mendeteksi penipuan?

  SMOTE terbukti efektif dalam meningkatkan kemampuan model dalam mendeteksi penipuan. Sebelum SMOTE, dataset sangat tidak seimbang sehingga model cenderung bias terhadap kelas normal dan sulit mengenali pola fraud.

  Setelah penerapan SMOTE, jumlah data menjadi seimbang (50:50), sehingga model dapat belajar pola dari kelas minoritas dengan lebih baik. Hal ini terlihat dari meningkatnya nilai **recall pada kelas fraud**, yang menunjukkan bahwa model lebih mampu mendeteksi transaksi penipuan.

  Namun demikian, penggunaan SMOTE juga perlu diperhatikan karena dapat meningkatkan risiko overfitting jika tidak dikombinasikan dengan evaluasi yang tepat.
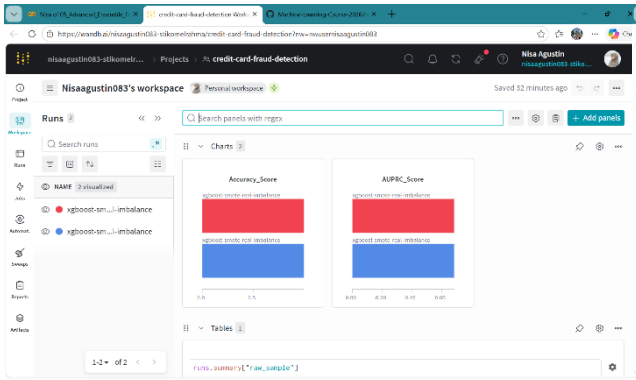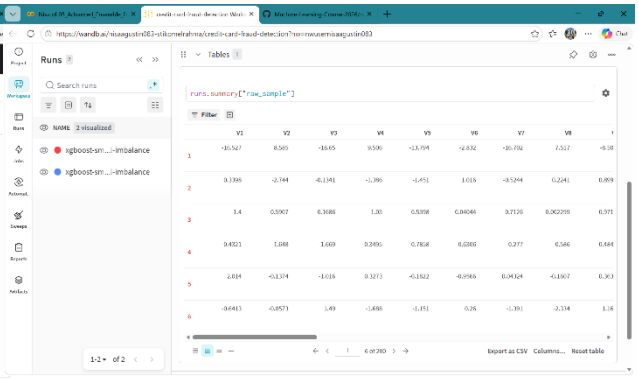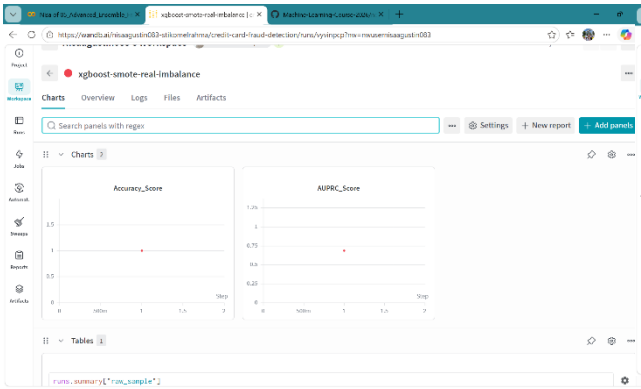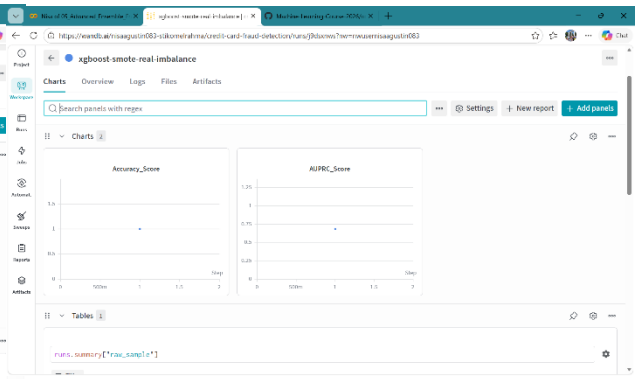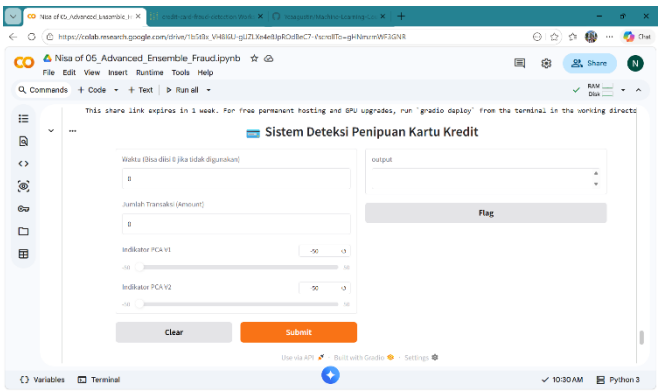
- Lampirkan screenshot grafik AUPRC dari dashboard W&B Anda.