



Laporan UTS Machine Learning 2026

Informasi Mahasiswa:

- **Nama:** Muhammad Ikhwan Manshur
- **NIM:** 2411070053
- **Project Link (W&B):**

https://colab.research.google.com/drive/1GtHyEm0DVOYLpe63cfu8Ry0XZOT9Vh_d

- **Pull Request Link (GitHub):**

<https://github.com/Xeno-Waan/Machine-Learning-Course-2026/tree/main/assignments/week-08>

1. Analisis Awal: Masalah Imbalance

Berdasarkan pengecekan `value_counts()` pada dataset asli:

Berapa jumlah transaksi Normal (Kelas 0)? 49915

Berapa jumlah transaksi Penipuan (Kelas 1)? 85

Analisis: Mengapa metrik Accuracy tidak boleh digunakan sebagai acuan utama dalam dataset ini?

Jawaban: Dataset ini sangat timpang, dengan kelas 'normal' jauh lebih dominan daripada kelas 'fraud'. Jika hanya menggunakan akurasi, sebuah model yang selalu memprediksi 'normal' akan menghasilkan akurasi sekitar 99.83%. Meskipun angkanya tinggi, model tersebut sebenarnya tidak mendeteksi penipuan sama sekali, yang berarti semua kasus penipuan akan terlewatkan (False Negative tinggi). Akurasi yang tinggi ini menyesatkan dan tidak mencerminkan kemampuan model yang sebenarnya dalam mengidentifikasi kelas minoritas yang krusial.

2. Implementasi SMOTE (Synthetic Minority Over-sampling Technique)

Lampirkan perbandingan jumlah data sebelum dan sesudah SMOTE:

Kondisi	Jumlah Data Kelas 0	Jumlah Data Kelas 1
Sebelum SMOTE	39932	68
Sesudah SMOTE	39932	39936

Analisis: Jelaskan bagaimana SMOTE bekerja "menciptakan" data baru untuk menyeimbangkan kelas penipuan.

Jawaban: SMOTE (Synthetic Minority Over-sampling Technique) bekerja dengan membuat sampel-sampel sintetis dari kelas minoritas (dalam kasus ini, transaksi fraud) alih-alih hanya menduplikasi sampel yang sudah ada. Prosesnya meliputi:

1. Pilih Sampel Minoritas: SMOTE memilih satu sampel dari kelas minoritas secara acak.
2. Temukan Tetangga Terdekat: Untuk sampel minoritas yang terpilih, SMOTE mencari k tetangga terdekatnya (berdasarkan fitur-fitur) dari kelas minoritas yang sama.
3. Hasilkan Sampel Sintetis: SMOTE kemudian membuat sampel baru secara acak di sepanjang segmen garis yang menghubungkan sampel minoritas asli dengan salah satu tetangga terdekatnya. Ini dilakukan dengan menginterpolasi fitur-fitur antara kedua sampel tersebut. Dengan cara ini, SMOTE menghasilkan pola data baru yang mirip dengan karakteristik kelas minoritas, sehingga dataset pelatihan menjadi lebih seimbang dan model dapat belajar pola dari kelas 'fraud' dengan lebih efektif.

3. Perbandingan Model: Bagging vs Boosting

Isi tabel perbandingan performa pada Data Test:

Metrik	Random Forest (Bagging)	XGBoost (Boosting)
Accuracy	0.9992	1.00
AUPRC	0.6562	0.6843
Recall (Kelas 1)	0.71	0.76
Precision (Kelas 1)	0.40	0.65

Pertanyaan Kritis:

1. Model mana yang memiliki nilai Recall tertinggi untuk transaksi Fraud (Kelas 1)? Mengapa nilai Recall sangat krusial bagi sebuah Bank?

Jawaban: Model XGBoost memiliki nilai Recall tertinggi untuk transaksi Fraud (Kelas 1) yaitu 0.76. Nilai Recall sangat krusial bagi sebuah Bank karena Recall mengukur proporsi kasus penipuan aktual yang berhasil diidentifikasi oleh model dari seluruh kasus penipuan yang ada. Dalam konteks deteksi penipuan, False Negative (transaksi penipuan yang tidak terdeteksi) berarti kerugian finansial langsung bagi bank. Memaksimalkan Recall berarti meminimalkan jumlah penipuan yang lolos dari deteksi, yang merupakan prioritas utama untuk mengurangi kerugian finansial dan menjaga kepercayaan pelanggan.

2. Berdasarkan hasil AUPRC, model mana yang paling stabil dalam membedakan penipu di tengah ribuan transaksi normal?

Jawaban: Berdasarkan hasil AUPRC, model XGBoost (dengan AUPRC 0.6843) adalah yang paling stabil dalam membedakan penipu. AUPRC (Area Under the Precision-Recall Curve) adalah metrik yang sangat relevan untuk dataset tidak seimbang karena fokus pada performa kelas minoritas. Nilai AUPRC yang lebih tinggi menunjukkan bahwa model lebih baik dalam mengidentifikasi kelas positif (fraud) tanpa mengorbankan terlalu banyak presisi, memberikan gambaran yang lebih akurat tentang kemampuan model dalam situasi imbalance.

4. Analisis Confusion Matrix

Lihat kuadran False Negative (Asli Fraud, tapi ditebak Normal) pada model terbaik Anda:

- Berapa jumlah penipu yang berhasil "lolos" dari deteksi model Anda?
- Jika Anda adalah manajer risiko bank, langkah apa yang akan Anda ambil untuk meminimalkan angka tersebut?

Jawaban: Jika saya adalah manajer risiko bank, langkah-langkah yang akan saya ambil untuk meminimalkan jumlah False Negative (penipu yang lolos) adalah:

1. Tuning Threshold: Mengeksplorasi penyesuaian threshold klasifikasi (saat ini 0.5 secara default). Dengan menurunkan threshold, model mungkin akan lebih agresif dalam mengklasifikasikan transaksi sebagai fraud, yang dapat meningkatkan Recall (menurunkan FN) meskipun mungkin akan ada sedikit peningkatan False Positive.

2. Fitur Tambahan dan Rekayasa Fitur: Mengidentifikasi dan menambahkan fitur-fitur baru yang mungkin relevan, seperti fitur temporal (waktu antar transaksi), interaksi fitur, atau fitur yang menggambarkan pola pengeluaran yang tidak biasa. Rekayasa fitur yang lebih canggih dapat membantu model menangkap pola penipuan yang lebih kompleks.

3. Model Ensemble Lanjutan atau Model yang Lebih Kompleks: Menggabungkan prediksi dari beberapa model (misalnya, stacked ensemble) atau mencoba arsitektur model yang lebih kompleks jika data memungkinkan, untuk meningkatkan kemampuan deteksi.

4. Sistem Peringatan Dini dan Intervensi Manusia: Mengintegrasikan model dengan sistem peringatan dini yang mengarahkan transaksi dengan probabilitas fraud yang tinggi (meskipun di bawah threshold utama) untuk ditinjau secara manual oleh tim analis fraud. Ini memungkinkan intervensi manusia untuk menangani kasus-kasus 'borderline' yang sulit diprediksi oleh model secara otomatis.

5. Pengumpulan Data Fraud yang Lebih Banyak: Jika memungkinkan, berusaha mengumpulkan lebih banyak data fraud historis untuk pelatihan, karena kualitas dan kuantitas data kelas minoritas sangat memengaruhi performa deteksi.

5. Kesimpulan & Dokumentasi W&B

Apa kesimpulan Anda mengenai efektivitas SMOTE dalam meningkatkan kemampuan model mendeteksi penipuan?

Jawaban: Berdasarkan eksperimen ini, SMOTE terbukti sangat efektif dalam mengatasi masalah ketidakseimbangan dataset yang parah dan secara signifikan meningkatkan kemampuan model dalam mendeteksi penipuan. Sebelum SMOTE, dengan hanya 68 kasus fraud di data latih, model akan sangat sulit belajar pola penipuan secara efektif. Setelah SMOTE, jumlah kelas minoritas menjadi seimbang dengan kelas mayoritas (sekitar 39.9 ribu kasus fraud sintetis), yang memungkinkan model (terutama XGBoost) untuk mencapai AUPRC yang solid (0.6843) dan Recall kelas 1 yang tinggi (0.76). Ini menunjukkan bahwa SMOTE berhasil "mengajarkan" model untuk mengidentifikasi pola-pola penipuan yang sebelumnya sulit ditemukan karena kelangkaan data, menjadikannya teknik krusial dalam skenario deteksi fraud.

