

Laporan UTS Machine Learning 2026

Nama : Salwa Hafizhah Yusuf

NIM : 2411070055

URL W&B Project : <https://wandb.ai/salwahafizhahyus-stikomelrahma/ml-challenge?nw=nwusersalwahafizhahyus>

Link Pull Request GitHub : https://github.com/shy-coding24/Machine-Learning-Course-2026/upload/main/assignments/week-08/2411070055_Salwa%20Hafizhah%20Y

1. Problem Statement & Dataset

- **Dataset yang digunakan :**
Dataset yang digunakan adalah diabetes.csv, yang berisi catatan medis pasien dan informasi apakah mereka menderita diabetes.
- **Masalah yang diselesaikan :**
Masalah yang ingin diselesaikan adalah klasifikasi, yaitu memprediksi apakah seorang pasien menderita diabetes (outcome = 1) atau tidak (outcome = 0) berdasarkan fitur-fitur medis yang diberikan
- **Mengapa Penting :**
Prediksi diabetes sejak dini sangat penting untuk intervensi medis yang tepat dan pengelolaan penyakit yang efektif, yang dapat mencegah komplikasi serius. Machine learning dapat membantu mengidentifikasi pola dalam data medis yang mungkin tidak terlihat oleh manusia, sehingga memungkinkan prediksi yang lebih akurat dan mendukung pengambilan keputusan klinis.

2. Exploratory Data Analysis (EDA)

a) Ceritakan temuan menarik dari data anda :

- **Jumlah baris dan kolom :** Dataset terdiri dari 768 baris dan 9 kolom.
- **Tipe data :** Integer (misalnya, Pregnancies, Glucose, Age), BMI, DiabetesPedigreeFunction adalah float.
- **Missing Values :** Tidak ditemukan nilai kosong (null) di seluruh dataset, yang disimpulkan dari `df.isnull().sum()`.

b) Apakah ada korelasi kuat? Apakah ada data yang timpang (imbalanced)?

- **Kolerasi :** Berdasarkan feature importance, Glucose, BMI, dan Age memiliki korelasi yang lebih kuat dengan outcome dibandingkan fitur lainnya
- **Data Imbalanced :** ya, data outcome (target) menunjukkan ketidakseimbangan. Visualisasi `sns.countplot(x='Outcome', data=df)` menunjukkan bahwa jumlah pasien tanpa diabetes (outcome=0) lebih banyak dibandingkan dengan pasien penderita diabetes (outcome=1). Ketidakseimbangan ini ditangani pada tahap preprocessing.

c) Tampilkan visualisasi utama Anda :

- Distribusi Variabel Target : Countplot dari outcome untuk menunjukkan ketidakseimbangan kelas.
- Confusion Matrix : Confusion matrix divisualisasikan untuk memahami performa klasifikasi.
- Feature Importance : Diagram batang yang menunjukkan pentingnya setiap fitur dalam model Random Forest.

3. Preprocessing & Feature Engineering

- **Langkah apa saja yang anda lakukan (handling missing values, scaling, encoding)?**

1. Pemisahan fitur dan target : kolom outcome dipisahkan sebagai variable target (y), dan sisa kolom lainnya sebagai fitur (x).
2. Pembagian Data : Data dibagi menjadi set pelatihan (80%) dan set pengujian (20%) menggunakan `train_test_split` dengan `random_state=42` untuk reproduktifitas.
3. Scaling Fitur : Fitur-fitur diskalakan menggunakan `StandardScaler`. Ini mengubah distribusi fitur agar memiliki rata-rata 0 dan standar deviasi 1, yang membantu model berbasis jarak atau gradien berkonvergensi lebih cepat dan berkinerja lebih baik.

- **Jika data imbalanced, bagaimana anda menanganinya? (SMOTE/Weighting)**

Karena data menunjukkan ketidakseimbangan kelas, saya menanganinya menggunakan Teknik SMOTE (Synthetic Minority, Over-sampling Technique). SMOTE digunakan pada set pelatihan (`x_train`, `y_train`) untuk membuat sampel sintetis dari kelas minoritas (pasien diabetes), sehingga menyeimbangkan distribusi kelas dan mencegah model bias terhadap kelas mayoritas.

4. Eksperimen Model (Battle of Algorithms)

Model	Accuracy	Recall (Class 1)	F1-Score (Class 1)
Logistic Regression	0.708	0.727	0.64
Decision Tree	0.695	0.655	0.61
Random Forest	0.753	0.764	0.69

5. Analisis Hasil & W&B Tracking

- Berdasarkan dashboard W&B, model mana yang paling unggul? **Random Forest Classifier**, dengan akurasi tertinggi sebesar 0.753.
- Analisis confusion matrix: Bagaimana model anda menangani false positive/negative?

a) Confusion matrix logistic regression:

- True positive (TP): 36 (Benar memprediksi diabetes)
- True Negative (TN): 69 (Benar memprediksi tidak diabetes)
- False Positive (FP): 30 (memprediksi diabetes, padahal tidak)
- False Negative (FN): 15 (memprediksi tidak diabetes, padahal diabetes)
- Recall class 1 = $40 / (40+15) = 0.727$

b) Confusion matrix decision tree:

- True Positive (TP): 36 (Benar memprediksi diabetes)
- True Negative (TN): 71 (Benar memprediksi tidak diabetes)
- False Positive (FP): 28 (memprediksi diabetes, padahal tidak)
- False Negative (FN): 19 (memprediksi tidak diabetes, padahal diabetes)
- Recall class 1 = $36 / (36+19) = 0.655$

c) Confusion matrix random forest:

- True Positive (TP): 42 (Benar memprediksi diabetes)
- True Negative (TN): 74 (Benar memprediksi tidak diabetes)
- False Positive (FP): 25 (memprediksi diabetes, padahal tidak)
- False Negative (FN): 13 (memprediksi tidak diabetes, padahal diabetes)
- Recall class 1 = $42 / (42+13) = 0.764$

Random forest memiliki false negative (13) paling rendah di antara ketiga model, yang berarti model ini paling baik dalam mengidentifikasi pasien diabetes sebenarnya. Meskipun False Positive (25) sedikit lebih tinggi dari Decision Tree, trade-off ini seringkali dapat diterima dalam konteks medis untuk tidak melewatkan kasus diabetes.

• Fitur apa yang paling berpengaruh (feature importance)?

Fitur yang paling berpengaruh secara signifikan dalam prediksi adalah:

- ✓ Glucose (Gula Darah)
- ✓ BMI (Indeks Massa Tubuh)
- ✓ Age (Usia)

Fitur-fitur lain seperti DiabetesPedigreeFunction, BloodPressure, Pregnancies, SkinThickness, dan Insulin juga berkontribusi, tetapi dengan bobot yang lebih rendah dibandingkan tiga fitur teratas.

6. Kesimpulan & Rekomendasi

- Apakah model siap digunakan di dunia nyata?

Model Random Forest menunjukkan performa yang cukup baik, terutama dalam mendeteksi kasus diabetes (recall class 1 = 0.764) setelah penggunaan SMOTE. Namun, untuk penggunaan klinis, performa ini masih perlu ditingkatkan dan divalidasi lebih lanjut.

- **Keterbatasan Model**

- Dataset relatif kecil (768 data)
- Fitur masih terbatas (belum mencakup faktor gaya hidup atau riwayat detail)
- Interpretasi model kurang transparan
- SMOTE berpotensi menimbulkan bias jika tidak divalidasi dengan baik