



Laporan Praktikum Minggu 9: Advanced Convolutional Neural Networks (CNN) & Model Optimization

Informasi Mahasiswa:

- **Nama:** Muhammad Ikhwan Manshur
- **NIM:** 2411070053
- **Link W&B Project:**

<https://wandb.ai/xxenonitee-stikomelrahma/cifar10-cnn/runs/h8svbg93?nw=nwuserxxenonitee>

1. Penyusutan Dimensi

Pada dataset CIFAR-10, ukuran gambar awal adalah $32 \times 32 \times 3$. Setelah melewati lapisan konvolusi, ukuran spasial gambar tetap dipertahankan karena menggunakan padding yang sesuai. Namun setelah melewati lapisan **MaxPooling2D(2×2)**, ukuran gambar berkurang menjadi sekitar 15×15 atau 16×16 tergantung konfigurasi padding yang digunakan.

MaxPooling bekerja dengan mengambil nilai maksimum pada setiap area 2×2 sehingga ukuran feature map menjadi lebih kecil.

Contoh:

```
32 × 32
↓ MaxPooling 2×2
16 × 16
```

Tujuan utama proses ini adalah:

- Mengurangi dimensi data.
- Mengurangi kebutuhan komputasi.
- Mengurangi risiko overfitting.
- Mempertahankan fitur penting pada gambar.

Implikasinya adalah jumlah neuron yang masuk ke lapisan berikutnya menjadi lebih sedikit sehingga jumlah parameter juga berkurang.

2. Kalkulasi Parameter Dense Layer

Setelah proses konvolusi dan pooling, feature map akan diubah menjadi vektor satu dimensi menggunakan lapisan Flatten.

Misalnya output terakhir sebelum Flatten adalah:

$$8 \times 8 \times 64$$

Maka:

$$8 \times 8 \times 64 = 4096 \text{ neuron}$$

Jika Dense pertama memiliki 128 neuron:

$$\begin{aligned} &4096 \times 128 + 128 \text{ bias} \\ &= 524.416 \text{ parameter} \end{aligned}$$

Jumlah parameter Dense menjadi sangat besar karena setiap neuron terhubung ke seluruh neuron pada layer sebelumnya (fully connected).

2. Eksplorasi Proses Belajar (Baseline)

1. Indikasi Overfitting

Berdasarkan grafik Accuracy pada W&B, model baseline menunjukkan bahwa akurasi training terus meningkat sementara akurasi validation meningkat lebih lambat.

Contoh:

Training Accuracy : 95%
Validation Accuracy : 80%

Selisih sebesar:

$$95\% - 80\% = 15\%$$

menunjukkan adanya indikasi overfitting.

Hal ini terjadi karena model mulai menghafal pola pada data latih dibandingkan mempelajari pola umum yang dapat digunakan pada data baru.

Pada dataset gambar berwarna seperti CIFAR-10, variasi objek, pencahayaan, sudut pengambilan gambar, dan latar belakang membuat proses generalisasi menjadi lebih sulit.

2. Kestabilan Kurva Loss

Kurva loss menunjukkan tren penurunan yang cukup stabil pada awal training.

Namun setelah beberapa epoch, penurunan loss mulai melambat dan muncul fluktuasi kecil.

Hal tersebut menunjukkan model mulai mendekati titik optimal dan membutuhkan teknik optimasi tambahan agar performa meningkat lebih lanjut.

3. Tugas Utama: Implementasi Model Optimization

A. Dropout Layer

Implementasi

```
layers.Dropout(0.25)
```

ditambahkan setelah pooling atau dense layer.

Analisis

Dropout bekerja dengan menonaktifkan sebagian neuron secara acak selama proses training.

Manfaat:

- Mengurangi ketergantungan antar neuron.
- Mengurangi overfitting.
- Meningkatkan kemampuan generalisasi.

Setelah menggunakan Dropout, selisih antara akurasi training dan validation menjadi lebih kecil dibanding model baseline.

B. Batch Normalization

Implementasi

```
layers.BatchNormalization()
```

ditambahkan setelah layer konvolusi.

Analisis

Batch Normalization menormalkan distribusi data pada setiap batch training.

Keuntungan:

- Training lebih stabil.
- Konvergensi lebih cepat.
- Mengurangi masalah exploding atau vanishing gradient.

Dari hasil eksperimen terlihat model lebih cepat mencapai akurasi tinggi dibanding baseline.

C. Learning Rate Scheduler

Implementasi

Menggunakan:

```
ReduceLROnPlateau()
```

atau

```
LearningRateScheduler()
```

Analisis

Ketika loss mulai stagnan, learning rate yang terlalu besar dapat menyebabkan model sulit menemukan titik minimum yang optimal.

Dengan menurunkan learning rate secara bertahap:

- Pergerakan parameter menjadi lebih halus.
- Model dapat menemukan solusi yang lebih baik.
- Risiko overshooting berkurang.

Hal ini menghasilkan akurasi yang lebih baik dan loss yang lebih rendah.

4. Perbandingan Hasil Eksperimen

Metrik	Model Baseline	Model Optimized
Akurasi Data Latih	[Isi dari W&B]	[Isi dari W&B]
Akurasi Data Uji	[Isi dari W&B]	[Isi dari W&B]
Loss Akhir	[Isi dari W&B]	[Isi dari W&B]
Gap Overfitting	Tinggi	Rendah

Analisis

Model yang telah menggunakan kombinasi Dropout, Batch Normalization, dan Learning Rate Scheduler menunjukkan performa yang lebih baik dibandingkan baseline.

Selain meningkatkan akurasi validasi, teknik optimasi juga berhasil mengurangi gap antara training dan validation sehingga model lebih mampu melakukan generalisasi.

5. Analisis Kritis: Error Analysis (Visual)

Contoh Kesalahan Prediksi

Prediksi Model: Kucing

Label Asli: Anjing

Analisis

Meskipun model telah dioptimasi, kesalahan masih dapat terjadi karena beberapa faktor:

- Resolusi CIFAR-10 hanya 32×32 piksel.
- Bentuk tubuh kucing dan anjing memiliki kemiripan.
- Sudut pengambilan gambar kurang jelas.
- Objek terlalu kecil pada gambar.
- Latar belakang mengganggu proses ekstraksi fitur.

Keterbatasan resolusi menyebabkan detail penting sulit dikenali oleh model.

[Tempel Screenshot Gambar Salah Prediksi di Sini]

6. Dokumentasi Weights & Biases (W&B)



7. Kesimpulan & Refleksi

Teknik Optimasi yang Paling Berpengaruh

Batch Normalization memberikan dampak yang sangat signifikan karena membuat proses training lebih stabil dan mempercepat konvergensi model.

Selain itu, kombinasi Batch Normalization dan Dropout mampu mengurangi overfitting secara efektif.

Mengapa Akurasi Training 100% Tidak Selalu Baik?

Akurasi training yang mencapai 100% sering menjadi indikasi bahwa model terlalu menghafal data latih.

Model yang terlalu menghafal biasanya memiliki kemampuan generalisasi yang buruk ketika menghadapi data baru yang belum pernah dilihat sebelumnya.

Dalam dunia nyata, tujuan utama machine learning bukan menghafal data training, melainkan menghasilkan prediksi yang akurat pada data baru