

Informasi Mahasiswa

Nama: Mush'ab Abdurrahman Fathin

NIM: 2411070062

Link W&B Project: <https://wandb.ai/mushab-a-fathin-stikomeIrahma/cifar10-cnn/runs/qgdys795>

1. Analisis Arsitektur Baseline

A. Penyusutan Dimensi

Penyusutan terjadi dalam dua tahap. Pertama, layer Conv2D(32, (3,3)) menggunakan kernel berukuran 3x3 tanpa padding (valid). Sesuai perhitungan output konvolusi $[32 - 3 + 1 = 30]$, dimensi gambar berkurang dari 32x32 menjadi 30x30. Kedua, proses MaxPooling2D((2,2)) membagi dimensi fitur tersebut menjadi setengahnya ($30 / 2 = 15$).

Implikasinya adalah penurunan jumlah parameter secara drastis untuk lapisan selanjutnya, mempercepat komputasi, membantu model mengompres serta mempertahankan fitur visual terpenting, dan mengurangi risiko overfitting.

B. Kalkulasi Parameter Dense Layer

Sebelum lapisan Flatten, output memiliki dimensi (6 x 6 x 64). Flatten mengubahnya menjadi vektor 1D berukuran 6 x 6 x 64 = 2304 neuron. Lapisan Dense(64) terhubung penuh ke 2304 neuron ini.

Menggunakan rumus parameter Dense yaitu $[(\text{input} \times \text{neuron}) + \text{bias}]$, maka perhitungannya adalah:

- Bobot (Weights): $2304 \times 64 = 147.456$
- Bias: 64
- Total Parameter: $147.456 + 64 = 147.520$ parameter.

2. Eksplorasi Proses Belajar (Baseline)

A. Indikasi Overfitting

Ya, terjadi indikasi overfitting. Pada Epoch ke-10, Akurasi Data Latih mencapai 78.32%, sedangkan Akurasi Validasi (Data Uji) hanya 69.97%. Terdapat selisih gap yang cukup besar yaitu sekitar 8.35%. Hal ini umum terjadi pada CNN tanpa optimasi karena model menjadi terlalu kompleks sehingga mulai menghafal (memorizing) fitur spesifik dari data latih, dan gagal menggeneralisasi (mengenali) pola abstrak dari gambar dataset validasi yang memiliki tingkat kerumitan tinggi.

B. Kestabilan

Kurva loss untuk data latih menurun secara halus (dari 1.4777 menjadi 0.6228). Namun, kurva validation loss (val_loss) tidak stabil dan mulai mengalami kenaikan. Val_loss mencapai titik terendahnya di 0.8616 pada Epoch 7, tetapi kemudian naik menjadi 0.8984 di Epoch 10, yang memperkuat bukti bahwa model mengalami overfitting setelah Epoch ke-7.

3. Tugas Utama: Implementasi Model Optimization

A. Dropout Layer

Posisi: Tambahkan `layers.Dropout(0.25)` setelah lapisan pooling atau lapisan dense.

Analisis: Dropout mengurangi selisih (gap) antara akurasi training dan validation karena secara acak "mematikan" sebagian neuron pada setiap iterasi training. Hal ini memaksa jaringan CNN untuk tidak hanya bergantung pada fitur dominan tertentu, melainkan mendistribusikan representasi fitur secara lebih merata ke seluruh neuron.

B. Batch Normalization

Posisi: Tambahkan `layers.BatchNormalization()` setelah lapisan konvolusi.

Analisis: Batch Normalization mempercepat konvergensi dan menstabilkan distribusi aktivasi pada setiap layer (mengatasi masalah internal covariate shift). Ini membuat proses training lebih stabil sehingga model bisa mencapai akurasi lebih tinggi dengan iterasi yang lebih sedikit.

C. Learning Rate Scheduler (Bonus Challenge)

Metode: Gunakan `tf.keras.callbacks.LearningRateScheduler` atau `ReduceLROnPlateau`.

Analisis: Penurunan Learning Rate (LR) secara dinamis sangat penting ketika grafik loss mulai melandai. Saat model mulai mendekati titik global minimum, langkah pembaruan bobot harus lebih kecil agar model bisa "masuk" ke titik paling optimal tanpa terus melompat melewati lembah error tersebut.

4. Perbandingan Hasil Eksperimen

Metrik	Model Baseline	Model Optimized (Dropout + BN + LR)
Akurasi Data Latih	78.32%	71.44%
Akurasi Data Uji	69.97%	71.24%
Loss Akhir (Val_loss)	0.8984	0.8242
Gap Overfitting	Tinggi (8.35%)	Sangat Rendah (0.20%)

5. Analisis Kritis: Error Analysis (Visual)

Teks Prediksi: (Misal: "Model memprediksi Gambar 5 sebagai Katak, aslinya Burung")



Analisis: Kesalahan CNN pada resolusi gambar 32x32 CIFAR-10 sering kali terjadi karena keterbatasan resolusi yang ekstrem, kemiripan bentuk (shape) antar kelas, gangguan latar belakang (background noise), atau posisi objek (angle).

Lebih rincinya, kesalahan dapat terjadi karena:

- Resolusi CIFAR-10 sangat kecil (32x32)
- Objek kurang jelas
- Background mirip dengan kelas lain
- Pencahayaan kurang baik
- Sudut pengambilan gambar berbeda

Kesimpulan: Meskipun model sudah dioptimasi, CNN tetap memiliki keterbatasan dalam mengenali objek yang ambigu atau memiliki kemiripan visual tinggi. Ukuran filter konvolusi dan pooling terkadang menghilangkan representasi tekstur penting di gambar resolusi rendah.

6. Dokumentasi Weights & Biases (W&B)



7. Kesimpulan & Refleksi

A. Teknik Optimasi Paling Berpengaruh

Kombinasi antara Dropout dan Batch Normalization pada layer Konvolusi. Lapisan CNN mengekstrak pola spasial, dan Dropout akan memaksa filter untuk mengidentifikasi berbagai 'feature map' alih-alih fitur tunggal, efektif memotong gap akurasi (overfitting).

B. Mengapa Akurasi 100% Training Berbahaya?

CNN dirancang untuk memahami "esensi" fitur lokal suatu objek, bukan merekam persis susunan piksel (MLP). Akurasi latih 100% menandakan model telah menghafal seluruh pola piksel dalam data latih secara presisi ('memorization'), sehingga kehilangan kemampuannya untuk mendeteksi variasi baru di dunia nyata ('poor generalization'). Model yang baik bukan hanya memiliki akurasi tinggi pada training, tetapi juga mampu mempertahankan performa pada data validasi dan data uji.