Laporan Praktikum Minggu 9: Advanced Convolutional Neural Networks (CNN) & Model Optimization

Nama : Raki Raihan

NIM : 2411070095

Link W&B Project : https://wandb.ai/han-dev321-stikomelrahma/cifar10-cnn

---

1. Analisis Arsitektur Baseline

Pada hasil model.summary () pada arsitektur awal didapatkan:

1. **Penyusutan Dimensi:**
   a. **Kenapa menyusut pada "Maxpooling2D":** karena pada lapisan ini "**Maxpooling2D**" ia menggunakan jendela 2*2 dengan langkah(*Stride*) sejauh 2 pixel. Dimana ia mereduksi dimensi gambar tepat ½ dari aslinya dengan hanya mengambil nilai pixel tertinggi dari setiap area 2*2. Daripada "**Conv2D**" filter ini berukuran 3*3 tanpa *padding* tambahan, sehingga tidak bisa memproses bagian paling pinggir gambar secara penuh. Akibatnya berkurang 2 pixel pada tinggi gambar.
   b. **Implikasi pada jumlah parameter** : penyusutan ini sangat penting, kenapa penting? Karena untuk mengurangi beban komputasi. Tanpa *Pooling*, jumlah parameter akan membengkak sangat besar pada lapisan dense, yang dapat menyebabkan model menjadi sangat lambat dan cepat mengalami *overfitting*.
2. **Kalkulasi Parameter :**
   Lapisan Dense (147.520): angka pada lapisan *Dense* pertama dihitung berdasarkan koneksi penuh antara hasil lapisan *Flatten* dengan jumlah neuron di lapisan tsb:
   a. **Input dari Flatten:** hasil max_pooling2d_1 → matriks 6*6 dengan 64 filter. Saat melewati *Flatten* → 6*6*64 = 2.304 neuron (input)
   b. **Koneksi ke dense:** 64 neuron merupakan penetapan nilai pada lapisan Dense pertama, dimana pada setiap neuron input (2.304) terhubung ke setiap neuron di lapisan *Dense* (64) → 2.304 (input) * 64 (neuron) = 147.456 bobot (weights)
   c. **Ditambah bias:** pada lapisan Dense juga memiliki 1 parameter tambahan di setiap neuron yang berupa bias → 147.456 + 64(Bias) = 147.520 total parameter.

---

2. Eksplorasi Proses Belajar (Baseline)

Analisis grafik **epoch/loss** & **epoch/accuracy** in W&B

1. **Indikasi Overfitting** : ya, mulai terlihat jelas pada paruh ke-2 pelatihan (setelah **epoch 5**)
    - **Selisih Akurasi :**
        - **Akurasi Data Latih (**accuracy**)** **:** sekitar **0,80** (**80%**)
        - **Akurasi Data Validasi (**val_accuracy**)** **:** di kisaran **0,68 – 0,70** (**68–80%**)
        - **Gap** **:** terdapat selisih sekitar **10-12%**
    - **Kenapa terjadi pada "CIFAR-10" :** karena Dataset gambar berwarna jauh lebih kompleks dibandingkan Dataset angka (*MNIST*). Dimana Dataset gambar berwarna memiliki variasi latar belakang, pencahayaan, dan sudut pandang yang beragam.

2. **Kestabilan Kurva Loss** :
   Grafik Kurva epoch/loss menunjukkan **penurunan secara halus** (**smooth**).
    - **Analisis Kestabilan:** garis biru (data latih) menurun dengan kosisten tanpa ada lompatan dratis (*Spikes*). Ini mengindikasikan bahwa penggunaan **Optimizer Adam** dengan **Learning Rate 0,001** sudah sangat tepat untuk dataset ini
    - **Catatan penting:** Meskipun kurva *loss* latihan menurun terus, pada grafik val_loss epoch terakhir (7-9) mulai sedikit menanjak kembali, dimana ini adalah sinyal merah klasik pada *Deep Learning* yang mengonfirmasi model sudah jago menghafal.

---

3. Tugas Utama: Implementasi Model Optimization

Modifikasi kode dengan menambahkan beberapa Teknik ke dalam arsitektur CNN:

A. Dropout Layer :
- **Posisi :** Layers.Dropout(0.25) stlh lapisan pooling atau dense
- **Analisis:** Dropout(0.25) akan secara acak "mematikan" 25% neuron selama setiap langkah pelatihan. Hal ini memaksa jaringan untuk tidak bergantung pada neuron tertentu saja.
- **Dampak pada Akurasi:** *Dropout* berfungsi untuk memperkecil seslisih (**gap**) antara akurasi *training* dan *validation*. Akan tetapi akan derdampak pada akurasi *training* yang sedikit turun karena proses belajar lebih "sulit", namun akurasi validation akan meningkat atau lebih stabil "biasanya" karena kemampuan generalisasi model meningkat.

B. Batch Normalization :
- **Posisi :** layers.BatchNormalization() stlh lapisan konvolusi
- **Analisis: BatchNormalization() fungsi**nya untuk **menormalisasi *output*** dari setiap **lapisan aktivasi** agar memiliki **rata-rata nol** dan **standar deviasi satu.**
- **Dampak Training:** prosesnya akan jauh **lebih stabil dan cepat.** Dengan Batch Normalization, *Learning Rate* bisa diatur lebih tinggi tanpa takut grafik *loss* bergojolak (osilasi). Pada tahap ini model akan mencapai akurasi tinggi dengan jumlah epoch lebih sedikit disbandingkan model baseline

C. **Learning Rate Scheduler (Challenge) :**

- **Metode :** memakai **ReduceLROnPlateau** yang berfungsi memantau **val_loss.** Dimana jika loss tidak turun dalam 3 epoch "misal", maka learning Rate akan dipotong
- **Analisis :** menurunkan *Learning Rate* saat grafik *Loss* mulai melandai sangat membantu model ibaratkan sedang mendekati "dasar lembah". Dimana:
  - Jika langkahnya tetap besar besar, model akan terus melompati titik terendah.
  - Hanya memperkecil langkah, model bisa melakukan penyesuaian bobot yang lebih halus (*Fine-tuning*) untuk menemukan titik koordinat yang presisi

---

4. Perbandingan Hasil Eksperimen

Table perbandingan berdasarkan log di dashboard W&B saya:

Metrik Metrik	Model Baseline	Model Optimized (Dropout+BN+LR)
Akurasi Data Latih	Sekitar **0.78** (78%)	Sekitar **0.79** (79%)
Akurasi Data Uji	Sekitar **0.69** (69%)	Sekitar **0.74** (74)
Loss Akhir	Sekitar **0.63** (63%)	Sekitar **0.60** (60%)
Gap Overfitting	(**Tinggi**/Rendah) "**val_loss** naik tajam di akhir"	(Tinggi/**Rendah**) "**val_loss** lebih stabil dan turun di akhir"

---

5. Analisis Kritis: Error Analysis (Visual)

Satu gambar dari data uji yang salah ditebak oleh model yang sudah dioptimasi

- **Teks Prediksi :** Model mengira katak "Frog", aslinya kucing/rusa "cat/deer"
- **Analisis :** dikarenakan oleh beberapa factor "**Posisi Objek**, **keterbatasan resolusi 32*32**, **tekstur mirip**, dan **kacau latar belakang**"

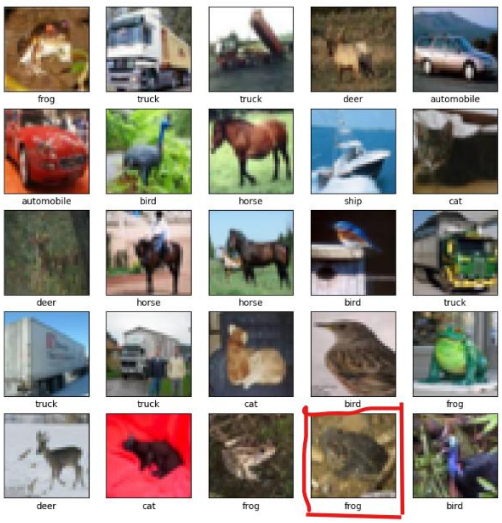

---

6. Dokumentasi Weights & Biases (W&B)

- **Baseline:**
  - **Accuracy :**

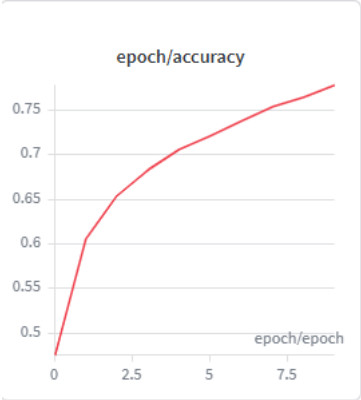

  - **Loss :**

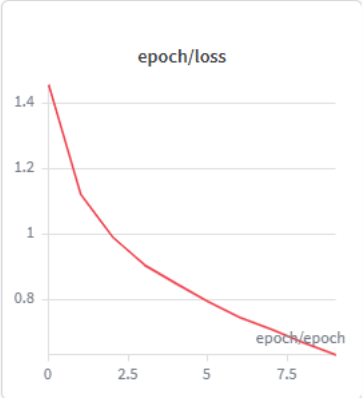

- **Optimasi:**
  - **Accuracy :**

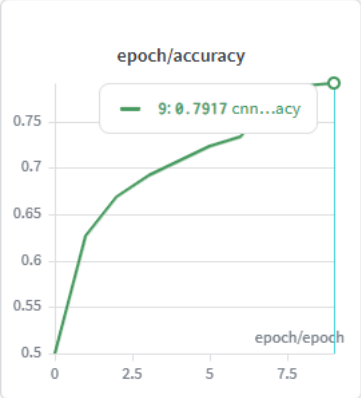

  - **Loss :**

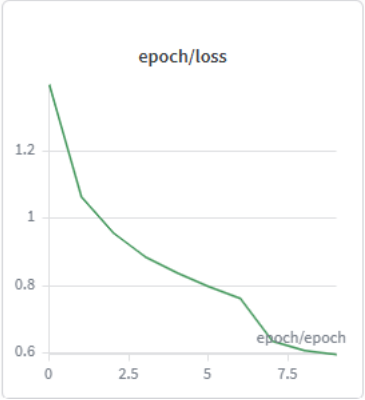

---

7. Kesimpulan & Refleksi

- **Teknik optimasi yang memberikan dampak signifikan:**
  Berdasarkan output hasil eksperimen di W&B: **Learning Rate Scheduler (ReduceLROnPlateau)** dan **Batch Normalization** adalah kombinasi yang memberikan dampak signifikan.

  - **Batch Normalization:** membuat proses latihan jauh lebih stabil sejak awal epoch awal, sehingga model tidak bergejolak saat mencoba mengenali gambar berwarna yang kompleks.
  - Akan tetapi **Learning Rate Scheduler "**kunci**"** yang menggebrak akurasi uji secara instan. Terlihat pada grafik, tepat saat *Learning Rate* dipotong (jadi lebih kecil), grafik **val_accuracy** langsung melonjak naik dan **val_loss** menurun tajam.

- **Kenapa akurasi 100% pada data training adalah indikasi buruk:**
  Karena akurasi 100% pada data training selalu mengindikasikan tanda **Overfitting** dalam klasifikasi gambar di dunia nyata, dan ini merupakan indikasi buruk karena:

  1. **Menghafal vs Memahami:** biasanya model tidak lagi belajar cara membedakan objek apabila mencapai akurasi 100%, melainkan **menghafal pixel demi pixel**

  2. **Ketidakmampuan Generalisasi:** jika model hanya menghafal data latih, maka model akan gagal total. Karena model menjadi "pintar di training" (data latih) tapi "bingung saat praktek" (data uji)