



Laporan Praktikum Minggu 11: General AI & ARG

Informasi Mahasiswa

- **Nama:** Muhammad Ikhwan Manshur
- **NIM:** 2411070053
- **Link W&B Project:**

<https://wandb.ai/xxenonitee-stikomelrahma/rag-pdf-chatbot-week11?nw=nwuserxxenonitee>

1. Konsep Large Language Models (LLM)

Jelaskan dengan bahasa Anda sendiri:

1. Apa yang dimaksud dengan fenomena **Hallucination** pada AI dan mengapa hal itu terjadi?
2. Bagaimana mekanisme **Retrieval-Augmented Generation (RAG)** mampu menutupi kelemahan LLM dalam hal data yang bersifat privat atau terbaru?

Jawaban:

1. **Hallucination (Halusinasi)** adalah situasi di mana model AI menghasilkan jawaban atau informasi yang terdengar sangat meyakinkan, logis, dan tata bahasanya rapi, namun secara faktual sepenuhnya salah atau mengarang bebas. Hal ini terjadi karena LLM bekerja berdasarkan prinsip statistik probabilitas untuk memprediksi kata berikutnya (*next-token prediction*) dari data latih masa lalunya, bukan dengan mencocokkan informasi ke basis data kebenaran real-time. Ketika LLM ditanya tentang informasi yang tidak ada di data latihnya, ia akan tetap mencoba memprediksi kata terdekad hingga menghasilkan fakta palsu.
2. **Mekanisme RAG** menutupi kelemahan tersebut dengan mengubah sistem kerja LLM dari ujian "tutup buku" menjadi ujian "buka buku". Ketika pengguna memberikan pertanyaan, sistem RAG akan mencari (*retrieve*) potongan dokumen atau data eksternal yang paling relevan dari basis data vektor (seperti ChromaDB yang berisi data dokumen privat atau terbaru). Potongan teks valid tersebut kemudian disisipkan ke dalam perintah (*prompt*) sebagai konteks rujukan sebelum dikirim ke LLM. Karena LLM dirancang untuk merangkum dan menjawab *hanya berdasarkan konteks dokumen* yang diberikan, ia tidak perlu lagi menebak-nebak, sehingga masalah data privat atau informasi terbaru dapat teratasi tanpa halusinasi.

2. Eksperimen Preprocessing (Chunking Strategy)

Dalam RAG, dokumen harus dipecah menjadi potongan kecil. Jelaskan pengaruh parameter berikut terhadap kualitas jawaban AI:

- 1. **Chunk Size:** Apa yang terjadi jika ukuran chunk terlalu besar atau terlalu kecil?
- 2. **Chunk Overlap:** Mengapa kita membutuhkan overlap antar potongan teks?

Jawaban:

- 1. **Pengaruh Chunk Size:**
 - o **Jika Terlalu Besar:** Teks penting yang dicari akan tercampur dengan banyak informasi sekunder lainnya di dalam satu potongan (*noise*). Hal ini membuat fokus LLM terpecah (*context dilution*), memperlambat performa, dan memboroskan kuota token prompt.
 - o **Jika Terlalu Kecil:** Informasi penting berisiko terpotong secara ekstrem sehingga kehilangan makna utuh kalimatnya (*loss of semantic context*). Akibatnya, LLM tidak bisa memahami hubungan sebab-akibat atau kesimpulan besar dari dokumen tersebut.
- 2. **Kebutuhan Chunk Overlap:**
 - o *Chunk Overlap* berfungsi sebagai jembatan informasi agar tidak ada teks atau data krusial yang terputus di tengah jalan saat proses pemotongan otomatis dilakukan. Dengan memberikan irisan atau teks yang berulang di setiap ujung potongan, awal kalimat di chunk berikutnya akan tetap menyambung dengan akhir kalimat di chunk sebelumnya, sehingga konteks informasi tetap terjaga secara utuh.

. Analisis Hasil: Baseline vs RAG

Tuliskan perbandingan jawaban AI untuk pertanyaan yang sama berdasarkan file PDF yang Anda gunakan.

Pertanyaan: Berapa pengaturan Aperture, Shutter Speed, dan ISO yang wajib digunakan pada formula eksposur Neoclassic Lighting?

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
Konten	"Maaf, saya tidak memiliki informasi spesifik mengenai formula eksposur untuk 'Neoclassic Lighting' karena istilah tersebut tidak umum	"Berdasarkan dokumen panduan, untuk formula eksposur Neoclassic Lighting wajib menggunakan rumus spesifik: Aperture diatur pada f/2.8 , Shutter Speed dikunci pada 1/160

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
	atau mungkin bagian dari panduan internal spesifik..."	detik , dan tingkat ISO dijaga pada ISO 64. "
Kebenaran	Mengarang / Tidak Tahu	Benar (Akurat 100%)

Analisis Kritis: Terjadi perubahan kualitas jawaban yang sangat drastis. Model Baseline (Tanpa RAG) gagal menjawab karena istilah "Neoclassic Lighting" beserta angka rumusnya sengaja kita buat secara rahasia di dalam file `panduan_fotografi_expert.pdf` dan tidak ada di internet umum. Setelah mengaktifkan RAG, AI tidak lagi mengalami halusinasi karena ia dipaksa membaca dokumen acuan di database ChromaDB terlebih dahulu, sehingga jawaban yang keluar menjadi sangat presisi dan faktual sesuai dengan isi dokumen asli.

4. Eksplorasi Relevansi (Top-K)

Coba ubah nilai k (jumlah potongan dokumen yang diambil untuk satu pertanyaan).

- **Nilai K yang dicoba:** 3 (Sesuai parameter `search_kwargs={"k": 3}` di kode kita).
- **Dampak:** Nilai $K=3$ sangat optimal untuk ukuran dokumen panduan pendek. AI mendapatkan potongan teks yang pas untuk merumuskan jawaban tanpa banjiriran teks yang tidak penting. Namun, jika nilai K dinaikkan terlalu besar (misal $K=10$), performa AI justru bisa menurun akibat masalah "*Lost in the Middle*", yaitu kondisi di mana informasi penting tenggelam atau terabaikan oleh LLM karena terlalu banyak dokumen sampah (*noise*) yang ikut disuntikkan ke dalam prompt.

5. Dokumentasi Weights & Biases (W&B)

runs.summary["Hasil_Perbandingan_RAG"]

Filter

Query	Baseline (Tanpa RAG)[-1]	Baseline (Tanpa RAG)[-1]	Baseline (Tanpa RAG)[-1]	RAG (Dengan RAG)	Source Citation
Berapa pengaturan Aperture, Shutter Speed, dan ISO yang wajib digunakan pada formula eksposur Neoclassic Lighting?	EoYhCoMhAQn51serti	Dalam dunia fotografi, **Neoclassic Lighting** (pencahayaan Neoklasik) adalah gaya yang terinspirasi dari lukisan-lukisan klasik abad ke-18 (seperti karya Rembrandt atau Caravaggio). Karakteristik utamanya adalah kontras yang dramatis antara cahaya dan bayangan ("chiaroscuro"), gradasi yang lembut, serta kesan yang elegan dan misterius.	text	Serdasarkan panduan teknis yang diberikan, pengaturan eksposur yang wajib digunakan dalam formula "The Golden Ratio Exposure" pada metode "Neoclassic Lighting" adalah: **Aperture:** Tepat pada **f/2.8** **Shutter Speed:** Wajib dikunci pada **1/160 detik** **ISO:** Harus dijaga pada nilai **ISO 64**	Halaman 1

6. Kesimpulan & Refleksi

1. Apa kendala terbesar Anda saat menghubungkan dokumen PDF ke dalam model AI?
2. Bagaimana teknologi RAG ini dapat diimplementasikan untuk membantu mahasiswa di kampus dalam mencari informasi akademik?

Jawaban:

1. **Kendala Terbesar:** Kendala teknis terbesar adalah sinkronisasi *environment* Google Colab yang sering kali membuat variabel API Key hilang di tengah jalan, serta adanya perubahan struktur (*breaking changes*) pada versi terbaru pustaka LangChain yang sempat memicu error `ModuleNotFoundError` pada folder `langchain.chains`. Kendala ini berhasil diatasi dengan menerapkan pendekatan **LCEL (LangChain Expression Language)** yang jauh lebih kokoh dan modern.
2. **Implementasi di Kampus:** Teknologi RAG ini bisa digunakan untuk membuat **Bot Pintar Layanan Akademik Kampus**. Seluruh dokumen PDF tebal seperti *Buku Pedoman Akademik*, *Panduan Tugas Akhir/Skripsi*, dan *SOP Pengajuan Beasiswa* bisa dimasukkan ke dalam database vektor. Mahasiswa cukup mengetik pertanyaan santai (misal: *"Berapa IPK minimal untuk daftar sidang?"*), dan AI akan langsung menyajikan jawaban instan yang akurat, lengkap dengan rujukan bab dan halaman aslinya tanpa membuat mahasiswa harus membaca ratusan halaman PDF secara manual.