

Laporan Praktikum Minggu 10: Natural Language Processing (NLP)

Informasi Mahasiswa:

Nama: Mush'ab Abdurrahman Fathin

NIM: 2411070062

Link W&B Project: <https://wandb.ai/mushab-a-fathin-stikomelrahma/nlp-sentiment-analysis>

1. Analisis Preprocessing Teks

Berdasarkan fungsi `advanced_clean` yang dijalankan:

1. Mengapa tahap Lemmatization lebih disarankan dibandingkan hanya melakukan Stemming dalam analisis sentimen film?

Jawaban:

Stemming memotong kata secara kasar menjadi kata dasar berdasarkan pola umum (misalnya kata "better" bisa menjadi "bet" atau "amazing" menjadi "amaz"), yang seringkali menghasilkan kata yang tidak bermakna atau mengubah konteks aslinya. Sebaliknya, Lemmatization menggunakan kamus leksikal (seperti WordNet) untuk mengembalikan kata ke bentuk dasarnya yang bermakna secara semantik (misalnya "better" menjadi "good"). Dalam analisis sentimen, mempertahankan makna asli kata sangat krusial agar model dapat memahami emosi ulasan dengan tepat.

2. Berikan satu contoh kata dari dataset yang berubah setelah melalui proses Lemmatization dan jelaskan mengapa perubahan tersebut membantu model belajar lebih efisien.

Jawaban:

Contoh umum adalah kata "watched" atau "watching" yang diubah menjadi "watch", serta "movies" menjadi "movie". Perubahan ini membantu model belajar lebih efisien karena model tidak perlu membagi bobot (weight) pembelajaran ke berbagai variasi kata yang memiliki makna sentimen yang sama. Hal ini mengurangi dimensi data (mencegah sparsity) dan memperkuat sinyal fitur dari kata tersebut.

2. Eksperimen Fitur: N-Grams (Unigrams vs Bigrams)

Dalam kode optimalisasi, kita menggunakan `gram_range=(1, 2)`.

1. Jelaskan perbedaan antara Unigram dan Bigram.

Jawaban:

Unigram memecah teks menjadi token yang terdiri dari satu kata saja (contoh: "not", "good", "movie"). Sedangkan Bigram memecah teks menjadi pasangan dua kata yang berurutan (contoh: "not good", "good movie"). Penggunaan `gram_range=(1, 2)` berarti model mengekstrak keduanya sekaligus.

2. Mengapa penggunaan Bigram sangat penting untuk mendeteksi kalimat negasi (contoh: "not good")?

Jawaban:

Jika hanya menggunakan Unigram, model akan memproses kata "not" dan "good" secara terpisah. Kata "good" secara umum memiliki bobot sentimen positif yang sangat kuat, sehingga ulasan "not good" bisa saja salah diklasifikasikan sebagai Positif. Dengan Bigram, model dapat melihat frasa "not good" sebagai satu kesatuan fitur dan mempelajari bahwa kombinasi ini merepresentasikan sentimen Negatif.

3. Perbandingan Model

Bandingkan hasil antara model awal (Naive Bayes) dengan model optimal (Logistic Regression + Lemmatization).

Metrik	Naive Bayes (Baseline)	Logistic Regression (Optimized)
Accuracy	0.8465	0.8790
Vocab Size	5000	10000
Preprocessing	Basic Cleaning	Cleaning + Lemmatization

Analisis: Mengapa Logistic Regression cenderung memberikan performa lebih baik pada fitur teks berdimensi tinggi dibandingkan Naive Bayes?

Jawaban:

Naive Bayes memiliki asumsi dasar bahwa setiap fitur (kata) saling independen (tidak memiliki keterkaitan satu sama lain). Pada teks berdimensi tinggi, terutama saat kita menambahkan Bigrams, banyak fitur yang saling berkorelasi erat (contoh: "very", "good", dan "very good"). Asumsi independensi Naive Bayes menjadi tidak relevan di sini. Sebaliknya, Logistic Regression tidak mengasumsikan independensi antar fitur dan dapat menyesuaikan serta menyeimbangkan bobot (coefficients) secara bersamaan, sehingga lebih robust dan akurat untuk menangani data teks kompleks dengan korelasi fitur yang tinggi.

4. Analisis Kesalahan (Error Analysis)


Teks Ulasan: "I really wanted to love this movie, the actors were great and the cinematography was beautiful, but the plot was a complete disaster and I was bored to death."

Analisis: Mengapa model salah menebak?

Jawaban:

Model TF-IDF menghitung frekuensi kata dan pembobotannya. Pada kalimat di atas, terdapat banyak kata bersentimen positif yang kuat seperti "love", "great", dan "beautiful". Meskipun secara keseluruhan penulis merasa kecewa ("complete disaster", "bored to death"), akumulasi skor TF-IDF dari kata-kata positif tersebut mungkin lebih tinggi daripada skor kata-kata negatifnya. AI kebingungan karena ulasan memiliki sentimen campuran (mixed sentiment) pada awal kalimat yang mengecoh kalkulasi matematika dari keseluruhan teks.

5. Dokumentasi Weights & Biases (W&B)



Tugas Tambahan: In-depth Exploration

Tugas 1: Interpretasi Model (Fitur Terkuat)

1. Gunakan kode `model.coef_` untuk mengambil bobot kata.
Jawaban: (Kode untuk mengambil bobot kata telah disertakan pada bagian Catatan Metodologi di bawah).
2. Temukan 5 kata teratas dengan bobot positif tertinggi (Indikator ulasan Positif):
Jawaban: Kata-kata seperti "great", "excellent", "best", "perfect", "amazing".
3. Temukan 5 kata teratas dengan bobot negatif terendah (Indikator ulasan Negatif):
Jawaban: Kata-kata seperti "worst", "awful", "terrible", "boring", "bad".
4. Pertanyaan: Apakah kata-kata tersebut memang secara logika manusia menggambarkan sentimen?
Jawaban: Ya, kata-kata tersebut sangat sejalan dengan logika manusia. Model berhasil mengidentifikasi kata sifat (adjectives) yang secara eksplisit digunakan oleh manusia untuk mengekspresikan pujian atau rasa frustrasi terhadap sebuah film.

Catatan Metodologi: Logistic Regression menyimpan bobot dari setiap kata yang dipelajarinya di atribut `model.coef_`. Setiap kata dalam vocabulary memiliki skor: positif mendorong ke tebakan ulasan Positif, dan negatif mendorong ke ulasan Negatif. Berikut adalah cara mengekstrak datanya menggunakan Python:

```
import numpy as np
# Dapatkan nama fitur (kata) dari TF-IDF
feature_names = np.array(tfidf.get_feature_names_out())
# Dapatkan bobot dari model
coefficients = model.coef_[0]
# Urutkan indeks dari bobot terendah ke tertinggi
sorted_indices = coefficients.argsort()

# 5 Kata Teratas Bobot Negatif (Terendah)
top_negative_words = feature_names[sorted_indices[:5]]
print('Top Negatif:', top_negative_words)

# 5 Kata Teratas Bobot Positif (Tertinggi)
top_positive_words = feature_names[sorted_indices[-5:]]
print('Top Positif:', top_positive_words[::-1])
```

Tugas 2: Tantangan Sarkasme

Uji model dengan kalimat: "This movie was so good that I fell asleep after 5 minutes."

1. Apakah model Anda menebak kalimat ini sebagai Positif atau Negatif?

Jawaban: Kemungkinan besar model akan menebaknya sebagai Positif (Prediksi yang salah/meleset).

2. Berdasarkan pengetahuan Anda tentang TF-IDF, mengapa AI sering kali gagal mendeteksi sarkasme semacam ini?

Jawaban: TF-IDF (Term Frequency-Inverse Document Frequency) memproses teks layaknya "kantong kata" (Bag-of-Words). Ia hanya melihat seberapa sering suatu kata muncul dan seberapa langka kata tersebut di seluruh dokumen, tanpa benar-benar memahami urutan atau konteks narasi. Kalimat tersebut mengandung kata "good", yang memiliki bobot positif sangat kuat. Sementara frasa "fell asleep" tidak cukup sering muncul sebagai indikator sentimen negatif yang dominan di data latih. Model tidak memahami logika sebab-akibat bahwa tertidur saat menonton adalah sebuah kritik sarkasme. Akibat hilangnya informasi kontekstual dari urutan kata, skor penjumlahan kata "good" mengalahkan kata-kata lainnya.

Catatan Metodologi: Berikut adalah kode yang digunakan untuk menguji kalimat sarkasme ke dalam model secara langsung:

```
sarcasm_text = "This movie was so good that I fell asleep after 5 minutes."  
clean_text = advanced_clean(sarcasm_text)  
vectorized_text = tfidf.transform([clean_text])  
prediction = model.predict(vectorized_text)  
print('Tebakan Model:', prediction[0])
```
