

Laporan Praktikum Minggu 11: Generative AI & RAG

Informasi Mahasiswa:

Nama	: Siti Yolanda Hareniza
NIM	: 2411070032
Link W&B Project	: https://wandb.ai/sitiyolandahareniza-stikomelrahma/rag-praktikum-minggu11
Link Repositori Proyek	: https://github.com/yolanland/praktikum-generative-ai-rag

1. Konsep Large Language Models (LLM)

Jelaskan dengan bahasa Anda sendiri:

1. Apa yang dimaksud dengan fenomena **Hallucination** pada AI dan mengapa hal itu terjadi?
2. Bagaimana mekanisme **Retrieval-Augmented Generation (RAG)** mampu menutupi kelemahan LLM dalam hal data yang bersifat privat atau terbaru?

Jawaban:

1. Hallucination adalah kondisi ketika Large Language Model (LLM) menghasilkan jawaban yang terdengar benar dan meyakinkan, tetapi sebenarnya tidak sesuai dengan fakta atau bahkan mengarang informasi. Hal ini terjadi karena LLM bekerja dengan memprediksi kata berikutnya berdasarkan pola yang dipelajari dari data pelatihan, bukan dengan mencari informasi langsung dari sumber yang valid. Jika model tidak memiliki informasi yang cukup atau pertanyaan berada di luar pengetahuannya, maka model tetap akan mencoba memberikan jawaban sehingga dapat menghasilkan informasi yang keliru.
2. Retrieval-Augmented Generation (RAG) mengatasi keterbatasan LLM dengan cara mengambil informasi yang relevan dari dokumen eksternal sebelum menghasilkan jawaban. Ketika pengguna mengajukan pertanyaan, sistem akan mencari potongan dokumen yang paling relevan menggunakan database vektor (ChromaDB), kemudian informasi tersebut diberikan sebagai konteks kepada LLM. Dengan cara ini, model tidak hanya mengandalkan pengetahuan hasil pelatihan, tetapi juga menggunakan isi dokumen yang diberikan, sehingga jawaban menjadi lebih akurat, dan dapat menjawab data terbaru.

2. Eksperimen Preprocessing (Chunking Strategy)

Dalam RAG, dokumen harus dipecah menjadi potongan kecil. Jelaskan pengaruh parameter berikut terhadap kualitas jawaban AI:

1. **Chunk Size:** Apa yang terjadi jika ukuran chunk terlalu besar atau terlalu kecil?
2. **Chunk Overlap:** Mengapa kita membutuhkan overlap antar potongan teks?

Jawaban:

1. Jika terlalu besar maka informasi banyak tetapi kurang fokus sehingga menjadi kurang spesifik karena satu chunk berisi terlalu banyak informasi yang belum tentu relevan dengan pertanyaan.
Jika terlalu kecil maka informasi kurang lengkap sehingga konteks dapat hilang.
2. Overlap menjaga kesinambungan informasi antar potongan teks sehingga konteks tidak terputus.

3. Analisis Hasil: Baseline vs RAG

Tuliskan perbandingan jawaban AI untuk pertanyaan yang sama berdasarkan file PDF yang Anda gunakan.

Pertanyaan: Bagaimana komputer membantu animator setelah proses keyframing selesai?

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
Konten	Setelah proses keyframing (pembuatan gerakan-gerakan kunci) selesai, peran komputer menjadi sangat krusial untuk menyelesaikan animasi hingga menjadi produk akhir. Komputer mengambil alih tugas-tugas teknis, matematis, dan berulang yang jika dilakukan manual akan memakan waktu sangat lama. Berikut adalah beberapa cara utama bagaimana komputer membantu animator setelah proses keyframing selesai: 1. Interpolasi dan Tweening Otomatis (In-betweening) Keyframing hanya menentukan posisi awal, tengah, dan akhir dari sebuah gerakan.	Berdasarkan referensi yang diberikan, setelah proses keyframing selesai, komputer akan membantu animator dengan cara menghitung dan membuat sendiri in-between secara otomatis. Dengan demikian, animator tidak perlu membuat in-between secara manual seperti yang dilakukan dalam animasi tradisional.

	Komputer kemudian menggunakan algoritma matematis (seperti Bezier curves atau splines) untuk mengisi bingkai gambar di antara kunci-kunci tersebut (in-betweens). Keuntungan: Gerakan menjadi sangat mulus tanpa animator harus menggambar atau menggerakkan objek bingkai demi bingkai (frame-by-frame). Animator juga bisa mengatur kurva kecepatan (akselerasi/deselerasi) dengan mudah lewat grafik komputer. 2. Simulasi Fisika dan Dinamika (Simulations) Untuk elemen-elemen yang terlalu rumit jika dianimasikan secara manual, komputer menggunakan mesin simulasi fisika (physics engine). Objek simulasi: Gerakan rambut, pakaian (kain), air, api, asap, debu, hingga efek gravitasi dan benturan. Keuntungan: Animator hanya perlu mengatur parameter (seperti kecepatan angin atau berat kain), dan komputer akan menghitung bagaimana elemen tersebut bereaksi secara realistis mengikuti gerakan karakter yang sudah di-keyframe. 3. Proses Rendering (Pencitraan) Rendering adalah proses di mana komputer menerjemahkan semua data 3D/vektor (model, gerakan, tekstur, cahaya) menjadi gambar 2D final berupa video. Peran komputer: Menghitung bagaimana cahaya memantul (menggunakan teknologi seperti Ray Tracing atau Global Illumination), membuat bayangan yang realistis, dan menghasilkan detail tekstur kulit, logam, atau kaca. Render Farm: Untuk proyek besar (seperti film Pixar atau Disney), ratusan komputer digabungkan (render farm) untuk memproses jutaan bingkai gambar secara paralel agar selesai lebih cepat. 4. Motion Blur dan Depth of Field Otomatis Secara alami, kamera asli memiliki keterbatasan yang membuat gambar terlihat sinematik, seperti efek buram saat bergerak cepat (motion blur) atau latar belakang yang tampak kabur (depth of field).	 Sumber Referensi • animasi.pdf (Halaman 6)
--	---	---

	Peran komputer: Menghitung kecepatan gerakan objek dari keyframe dan secara otomatis menambahkan efek blur yang realistis pada frame yang tepat, serta mensimulasikan lensa kamera film. 5. Compositing (Penggabungan Gambar) Karakter yang sudah dianimasikan sering kali diproduksi terpisah dari latar belakang (background) atau efek visual lainnya. Peran komputer: Software compositing (seperti Adobe After Effects atau Nuke) membantu menyatukan semua lapisan (karakter, latar belakang, partikel debu, pencahayaan ekstra) menjadi satu kesatuan yang menyatu secara alami. 6. Sinkronisasi Suara Otomatis (Lip-Sync bertenaga AI) Mencocokkan gerakan mulut karakter dengan suara dialog (dubbing) bisa sangat melelahkan. Peran komputer: Saat ini, banyak software animasi menggunakan kecerdasan buatan (AI) yang dapat menganalisis file audio suara manusia dan secara otomatis menyesuaikan gerakan mulut karakter (bentuk huruf vokal/konsonan) agar pas dengan suara tersebut. 7. Pengoreksian Warna (Color Grading) dan Editing Setelah semua gambar selesai di-render, komputer digunakan untuk menyunting urutan adegan dan melakukan color grading agar warna di setiap adegan terlihat konsisten dan mendukung atmosfer cerita (misalnya memberikan nuansa biru dingin untuk adegan sedih). Kesimpulan: Setelah keyframing selesai, komputer bertindak sebagai "asisten jenius" yang menangani perhitungan matematika rumit, simulasi fisika, pencahayaan, dan penggabungan visual. Ini memungkinkan animator untuk fokus pada aspek kreatif dan seni, sementara komputer menyelesaikan detail teknisnya.	
Kebenaran	Benar secara umum, tetapi tidak mengacu pada isi dokumen.	Benar dan sesuai dengan isi dokumen PDF.

Analisis Kritis: Jelaskan perubahan kualitas jawaban yang Anda amati. Apakah AI masih mengalami halusinasi meskipun sudah diberi data pendukung?

Jawaban: Pada mode Baseline, memberikan jawaban berdasarkan pengetahuan umum yang dimiliki model sehingga jawabannya cukup benar, namun tidak mengacu pada PDF yang digunakan dalam pengujian. Sedangkan, pada mode RAG jawaban dihasilkan berdasarkan isi PDF yang telah diproses sehingga lebih spesifik dan sesuai dengan materi referensi. Pada pengujian ini, RAG mampu mengurangi kemungkinan terjadinya halusinasi karena model menggunakan informasi yang berasal dari dokumen sebagai dasar penyusunan jawaban.

4. Eksplorasi Relevansi (Top-K)

Coba ubah nilai k (jumlah potongan dokumen yang diambil untuk satu pertanyaan).

Nilai K yang dicoba: 3, 4, 10

Dampak: Apakah mengambil lebih banyak dokumen selalu membuat jawaban AI lebih baik, atau justru membuatnya bingung?


Jawaban: Saat nilai Top-K 3, hanya sedikit potongan dokumen yang digunakan sehingga jawaban menjadi lebih fokus tetapi terkadang kurang lengkap.

Saat nilai Top-K 10, model menerima lebih banyak informasi sehingga jawaban menjadi lebih panjang. Namun, jika terlalu banyak potongan yang kurang relevan ikut diambil, jawaban dapat menjadi kurang fokus.

Pada praktik ini, Top-K 4 memberikan hasil terbaik karena mampu menghasilkan jawaban yang cukup lengkap tanpa memasukkan terlalu banyak informasi yang tidak diperlukan.

5. Dokumentasi Weights & Biases (W&B)

Lampirkan *screenshot* dari *dashboard* W&B Anda yang menampilkan log tabel perbandingan pertanyaan dan jawaban.



Gambar 1 Dashboard W&B

6. Kesimpulan & Refleksi

1. Apa kendala terbesar Anda saat menghubungkan dokumen PDF ke dalam model AI?
2. Bagaimana teknologi RAG ini dapat diimplementasikan untuk membantu mahasiswa di kampus dalam mencari informasi akademik?

Jawaban:

1. Kendala terbesar saat menghubungkan dokumen PDF ke model AI adalah proses konfigurasi API Google Gemini dan integrasi dokumen ke dalam ChromaDB. Selain itu, saya juga mengalami keterbatasan kuota (quota limit) pada Gemini API sehingga beberapa pengujian RAG tidak dapat dilakukan secara berulang dalam waktu singkat. Masalah tersebut diatasi dengan mengganti API Key yang masih memiliki kuota dan melakukan pengujian kembali setelah kuota tersedia. Setelah konfigurasi selesai, sistem dapat memproses dokumen PDF dan menghasilkan jawaban berdasarkan isi dokumen dengan baik.
2. RAG dapat membantu mahasiswa mencari informasi dari modul, jurnal, atau materi kuliah dengan cepat dan menghasilkan jawaban yang lebih akurat berdasarkan dokumen yang tersedia.