

Laporan Praktikum Minggu 11: Generative AI & RAG

Informasi Mahasiswa:

- **Nama:** Nisa Agustin
- **NIM:** 2411070040
- **Link W&B Project:** <https://wandb.ai/nisaagustin083-stikomelrahma/tugas-ml-rag-gemini>
- **Link Repositori Proyek:** [Machine-Learning-Course-2026/assignments/week-11/2411070040](https://github.com/NisaAgustin/Machine-Learning-Course-2026/assignments/week-11/2411070040) Nisa Agustin at main · Ycaagustin/Machine-Learning-Course-2026

1. Konsep Large Language Models (LLM)

Jelaskan dengan bahasa Anda sendiri:

1. Apa yang dimaksud dengan fenomena **Hallucination** pada AI dan mengapa hal itu terjadi?
2. Bagaimana mekanisme **Retrieval-Augmented Generation (RAG)** mampu menutupi kelemahan LLM dalam hal data yang bersifat privat atau terbaru?

Jawaban:

1. Hallucination itu kondisi saat AI memberikan jawaban yang terdengar benar dan meyakinkan, tapi sebenarnya informasi tersebut tidak sesuai dengan fakta dan bisa jadi di buat-buat. Ini terjadi karena LLM menghasilkan jawaban berdasarkan pola dari data yang udah di pelajari pas proses latihan. Akibatnya, jika AI tidak memiliki informasi yang sesuai, model akan tetap mencoba memberikan jawaban meskipun jawabannya belum tentu benar.

2. RAG bekerja dengan mengambil informasi yang relevan dari dokumen yang telah disimpan di dalam Vector Database sebelum AI menyusun jawaban. Dengan cara ini, AI tidak hanya mengandalkan pengetahuan yang dimiliki saat proses pelatihan, tetapi juga menggunakan informasi dari dokumen yang diberikan. Oleh karena itu, RAG mampu menjawab pertanyaan mengenai data terbaru maupun data yang bersifat privat, selama informasi tersebut terdapat pada dokumen yang dimasukkan ke dalam sistem.

2. Eksperimen Preprocessing (Chunking Strategy)

Dalam RAG, dokumen harus dipecah menjadi potongan kecil. Jelaskan pengaruh parameter berikut terhadap kualitas jawaban AI:

1. **Chunk Size:** Apa yang terjadi jika ukuran chunk terlalu besar atau terlalu kecil?
2. **Chunk Overlap:** Mengapa kita membutuhkan overlap antar potongan teks?

Jawaban:

1. Jika ukuran chunk terlalu besar, satu potongan akan berisi terlalu banyak informasi sehingga proses pencarian menjadi kurang spesifik dan AI dapat mengambil informasi yang tidak relevan. Sedangkan jika ukuran chunk terlalu kecil, informasi penting dapat terpecah menjadi beberapa bagian sehingga konteks menjadi tidak lengkap dan jawaban AI menjadi kurang akurat.

2. Chunk Overlap digunakan agar antar potongan dokumen tetap memiliki sebagian isi yang sama. Tujuannya supaya informasi yang berada di batas antara dua chunk tidak hilang.

Dengan adanya overlap, AI lebih mudah memahami hubungan antar kalimat sehingga jawaban menjadi lebih lengkap dan tidak kehilangan konteks penting.

3. Analisis Hasil: Baseline vs RAG

Tuliskan perbandingan jawaban AI untuk pertanyaan yang sama berdasarkan file PDF yang Anda gunakan.

Pertanyaan:

Berapa target keuntungan bersih yang ditetapkan untuk Toko Niscare pada Kuartal Ke-4 tahun 2026 dan apa saja teknologi pendukungnya?

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
Konten	Sebagai model AI, saya tidak memiliki akses ke data internal atau rencana bisnis spesifik Toko Niscare, karena itu adalah entitas fiktif atau yang tidak saya kenal dalam database saya. Oleh karena itu, saya tidak bisa memberikan angka target keuntungan bersih yang "ditetapkan" untuk Toko Niscare pada Kuartal Ke-4 tahun 2026. **Namun, jika Toko Niscare adalah toko ritel yang beroperasi, target keuntungan bersih untuk Q4 2026 akan ditentukan berdasarkan:** **Kinerja Historis:** Data penjualan dan keuntungan dari kuartal-kuartal sebelumnya. **Kondisi Pasar:** Tren industri, daya beli konsumen, dan persaingan di tahun 2026. **Strategi Pertumbuhan:** Rencana ekspansi, peluncuran produk baru, atau kampanye pemasaran. **Efisiensi Operasional:** Upaya untuk mengurangi biaya dan meningkatkan margin.	Target keuntungan bersih yang ditetapkan untuk Toko Niscare pada Kuartal Ke-4 tahun 2026 adalah sebesar Rp150.000.000 (Seratus Lima Puluh Juta Rupiah). Teknologi pendukungnya meliputi: * Ekspansi integrasi WhatsApp Gateway otomatis untuk pengiriman resi pembayaran. * Adopsi sistem headless commerce Scalev. * Integrasi simulator payment gateway Midtrans untuk transaksi instan di wilayah Bogor Tengah dan sekitarnya.

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
	5. **Proyeksi Penjualan:** Estimasi pendapatan berdasarkan faktor-faktor di atas. **Sebagai ilustrasi hipotetis**, sebuah toko ritel skala menengah mungkin menargetkan keuntungan bersih antara **Rp 50.000.000 hingga Rp 150.000.000** untuk satu kuartal, tergantung pada ukuran, jenis produk, lokasi, dan strategi penjualannya. --- **Teknologi Pendukung untuk Toko Niscare pada Kuartal Ke-4 tahun 2026:** Untuk mencapai target keuntungan dan meningkatkan efisiensi, Toko Niscare kemungkinan akan memanfaatkan berbagai teknologi pendukung, terutama mengingat tahun 2026 di mana digitalisasi akan semakin matang: **Sistem Point of Sale (POS) Terintegrasi:** **Fungsi:** Memproses transaksi, mengelola inventaris secara <i>*real-time*</i>, melacak data penjualan, dan mengelola program loyalitas pelanggan. **Fitur 2026:** Integrasi dengan pembayaran digital (QRIS, e-wallet, kartu), <i>*self-checkout*</i> (opsional), dan analisis penjualan instan. **Sistem Manajemen Inventaris Otomatis:** **Fungsi:** Memantau stok barang masuk dan keluar, memberikan notifikasi untuk	

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
	restock, mengurangi *dead stock*, dan mencegah kehilangan. * **Fitur 2026:** Penggunaan RFID atau sensor IoT untuk pelacakan barang yang lebih akurat, prediksi permintaan berbasis AI untuk optimasi stok. 3. **Platform E-commerce dan Omnichannel:** * **Fungsi:** Memungkinkan pelanggan berbelanja secara online, baik melalui website toko sendiri maupun marketplace. Integrasi antara toko fisik dan online. * **Fitur 2026:** Pengalaman belanja personalisasi, *click-and-collect*, *delivery tracking*, dan integrasi dengan media sosial. 4. **Customer Relationship Management (CRM) System:** * **Fungsi:** Mengelola data pelanggan, riwayat pembelian, preferensi, dan interaksi untuk membangun loyalitas dan menawarkan promosi yang relevan. * **Fitur 2026:** Personalisasi penawaran berbasis AI, program loyalitas digital, dan komunikasi otomatis melalui email/aplikasi. 5. **Analisis Data dan Business Intelligence (BI):** * **Fungsi:** Mengumpulkan dan menganalisis data penjualan, perilaku pelanggan, tren pasar, dan kinerja operasional untuk pengambilan keputusan yang lebih baik. * **Fitur 2026:** Dashboard interaktif, laporan prediktif (misalnya, prediksi penjualan untuk musim liburan), dan identifikasi peluang pertumbuhan.	

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
	6. **Sistem Pembayaran Digital dan Nirsentuh:** * **Fungsi:** Mendukung berbagai metode pembayaran digital (QRIS, e-wallet, *contactless card*, *tap-to-pay* via smartphone) untuk kenyamanan pelanggan. * **Fitur 2026:** Keamanan transaksi yang ditingkatkan, integrasi dengan program loyalitas, dan opsi pembayaran cicilan digital. 7. **Pemasaran Digital dan Otomatisasi:** * **Fungsi:** Menggunakan media sosial, email marketing, SEO, dan iklan berbayar untuk menjangkau pelanggan baru dan mempertahankan yang lama. * **Fitur 2026:** Otomatisasi kampanye pemasaran, *chatbot* untuk layanan pelanggan 24/7, dan personalisasi iklan berbasis AI. 8. **Keamanan dan Pengawasan Pintar:** * **Fungsi:** Kamera CCTV berbasis AI untuk memantau aktivitas di toko, mendeteksi pencurian, dan menganalisis pola lalu lintas pelanggan. * **Fitur 2026:** Pengenalan wajah (untuk staf/pelanggan VIP), deteksi anomali, dan integrasi dengan sistem alarm. Dengan kombinasi teknologi ini, Toko Niscare dapat meningkatkan efisiensi operasional, memperluas jangkauan pasar, meningkatkan pengalaman pelanggan, dan pada akhirnya, mencapai target keuntungan bersih yang ambisius di Q4 2026.	

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
Kebenaran	Mengarang (Hallucination)	Benar(Sesuai isi PDF)

Analisis Kritis: Jelaskan perubahan kualitas jawaban yang Anda amati. Apakah AI masih mengalami halusinasi meskipun sudah diberi data pendukung?

Jawaban : Sebelum menggunakan RAG, AI tidak mengetahui isi dokumen sehingga hanya memberikan jawaban berdasarkan pengetahuan umum. Jawaban tersebut terlihat meyakinkan, tetapi tidak sesuai dengan isi PDF.

Setelah menggunakan RAG, AI dapat mengambil informasi langsung dari dokumen sehingga jawaban menjadi lebih spesifik, akurat, dan sesuai dengan data yang tersedia. Pada pengujian ini, halusinasi berhasil dikurangi karena model menjawab berdasarkan konteks yang ditemukan di Vector Database.

4. Eksplorasi Relevansi (Top-K)

Coba ubah nilai k (jumlah potongan dokumen yang diambil untuk satu pertanyaan).

- **Nilai K yang dicoba: 3**
- **Dampak:** Apakah mengambil lebih banyak dokumen selalu membuat jawaban AI lebih baik, atau justru membuatnya bingung?


Jawaban : Pada pengujian ini digunakan nilai **Top-K = 3**, sehingga AI mengambil tiga potongan dokumen yang paling relevan sebelum menyusun jawaban.

Semakin besar nilai K tidak selalu menghasilkan jawaban yang lebih baik. Jika terlalu banyak potongan dokumen diambil, informasi yang kurang relevan dapat ikut masuk sehingga jawaban menjadi lebih panjang atau bahkan kurang fokus. Sebaliknya, jika nilai K terlalu kecil, ada kemungkinan informasi penting tidak ikut terambil. Jadi, pemilihan nilai K perlu disesuaikan dengan jenis dokumen dan kebutuhan pencarian.

5. Dokumentasi Weights & Biases (W&B)

Lampirkan *screenshot* dari *dashboard* W&B Anda yang menampilkan log tabel perbandingan pertanyaan dan jawaban.

Pertanyaan	Jawaban Tanpa RAG (Baseline)	Jawaban Dengan RAG (Top-K=3)
Serapa target keuntungan bersih yang ditetapkan untuk Toko Niscare pada kuartal Ke-4 tahun 2026 dan apa saja teknologi pendukungnya?	Sebagai model AI, saya tidak memiliki akses ke data internal atau rencana bisnis spesifik Toko Niscare, karena itu adalah entitas fiktif atau yang tidak saya kenal dalam database saya. Oleh karena itu, saya tidak bisa memberikan angka target keuntungan bersih yang "ditetapkan" untuk Toko Niscare pada Kuartal Ke-4 tahun 2026. **Namun, jika Toko Niscare adalah toko ritel yang beroperasi, target keuntungan bersih untuk Q4 2026 akan ditentukan berdasarkan:** 1. "Kinerja Historis": Data penjualan dan keuntungan dari kuartal-kuartal sebelumnya. 2. "Kondisi Pasar": Tren industri, daya beli konsumen, dan persaingan di tahun 2026. 3. "Strategi Pertumbuhan": Rencana ekspansi, peluncuran produk baru, atau kampanye pemasaran. 4. "Efisiensi Operasional": Upaya untuk mengurangi biaya dan meningkatkan margin. 5. "Proyeksi Penjualan": Estimasi pendapatan berdasarkan faktor-faktor di atas. **Sebagai ilustrasi hipotetis**, sebuah toko ritel skala menengah mungkin menetapkan keuntungan bersih Q4 sebesar 15%.	Target keuntungan bersih yang ditetapkan untuk Toko Niscare pada Kuartal Ke-4 tahun 2026 adalah sebesar Rp150.000.000 (Seratus Lima Puluh Juta Rupiah). Teknologi pendukungnya meliputi: * Ekspansi integrasi WhatsApp gateway otomatis untuk pengiriman resi pembayaran. * Adopsi sistem headless commerce Scalv. * Integrasi simulator payment gateway Midtrans untuk transaksi instan di wilayah Bogor Tengah dan sekitarnya.



6. Kesimpulan & Refleksi

1. Apa kendala terbesar Anda saat menghubungkan dokumen PDF ke dalam model AI?

Kendala terbesarnya saat perubahan versi library dan model Gemini. Notebook praktikum masih menggunakan model lama seperti embedding-001 dan gemini-1.5-flash, sedangkan API Google yang digunakan sudah mendukung model terbaru seperti gemini-embedding-001 dan gemini-2.5-flash. Terus saya juga mengalami beberapa error kaya cell yang ke 3 itu merah tombol playnya dan gak mau jalan, sehingga perlu memperbarui model dan beberapa bagian kode agar kompatibel dengan versi terbaru.

2. Bagaimana teknologi RAG ini dapat diimplementasikan untuk membantu mahasiswa di kampus dalam mencari informasi akademik?

Teknologi RAG dapat dimanfaatkan sebagai asisten pencarian informasi akademik di kampus. Mahasiswa juga bisa mengunggah dokumen seperti buku panduan akademik, peraturan kampus, modul perkuliahan, atau jurnal, kemudian mengajukan pertanyaan menggunakan bahasa sehari-hari. Sistem akan mencari informasi yang relevan dari dokumen tersebut dan memberikan jawaban yang lebih akurat dibandingkan LLM biasa. Jadi, mahasiswa dapat memperoleh informasi dengan lebih cepat tanpa harus membaca seluruh isi dokumen secara manual.