

UAS: Generative AI & RAG

Nama : Salwa Hafizhah Yusuf
NIM : 2411070055
Link W&B Project : <https://wandb.ai/salwahafizhahyus-stikomelrahma/UAS-RAG-Gemini?nw=nwusersalwahafizhahyus>
Link Repositori Proyek: https://github.com/shy-coding24/Machine-Learning-Course-2026/tree/main/assignments/week-11/2411070055_Salwa%20Hafizhah%20Yusuf

A. Konsep Large Language Models (LLM)

1. Apa yang dimaksud dengan fenomena Hallucination pada AI dan mengapa hal itu terjadi?

Hallucination merupakan kondisi ketika Large Language Model (LLM) menghasilkan jawaban yang terdengar meyakinkan tetapi sebenarnya tidak sesuai dengan fakta atau tidak didukung oleh sumber informasi yang valid. Hal ini terjadi karena LLM bekerja dengan memprediksi kata berikutnya berdasarkan pola yang dipelajari dari data pelatihan, bukan mengambil informasi secara langsung dari basis data atau internet. Ketika model tidak memiliki informasi yang cukup atau pertanyaan berada di luar cakupan data latihnya, model dapat memberikan jawaban yang keliru atau bahkan mengarang informasi.

2. Bagaimana mekanisme Retrieval-Augmented Generation (RAG) mampu menutupi kelemahan LLM dalam hal data yang bersifat privat atau terbaru?

Retrieval-Augmented Generation (RAG) mengatasi keterbatasan LLM dengan mengambil informasi dari dokumen eksternal sebelum menghasilkan jawaban. Pada proyek ini, dokumen PDF diproses menjadi beberapa potongan teks (*chunks*), kemudian setiap potongan diubah menjadi embedding menggunakan SentenceTransformer dan disimpan pada FAISS sebagai vector database. Ketika pengguna mengajukan pertanyaan, sistem akan mencari potongan dokumen yang paling relevan menggunakan similarity search, lalu mengirimkan hasil pencarian tersebut sebagai konteks ke model Gemini. Dengan demikian, jawaban yang dihasilkan mengacu pada isi dokumen sehingga lebih akurat dan dapat menjawab informasi yang bersifat privat maupun terbaru.

B. Eksperimen Preprocessing (Chunking Strategy)

1. Chunk Size:

Pada implementasi ini digunakan ukuran *chunk* sebesar **500 karakter**. Ukuran *chunk* mempengaruhi kualitas informasi yang diterima model. Jika ukuran *chunk* terlalu kecil, informasi penting dapat terpotong sehingga konteks menjadi kurang lengkap dan jawaban yang dihasilkan kurang akurat. Sebaliknya, jika ukuran *chunk* terlalu besar, proses pencarian menjadi kurang spesifik karena satu *chunk* memuat terlalu banyak informasi yang belum tentu relevan dengan pertanyaan pengguna. Oleh karena itu, ukuran 500 karakter dipilih agar setiap *chunk* tetap memiliki konteks yang cukup namun masih mudah dicari berdasarkan kemiripan.

2. Chunk Overlap

Pada proyek ini digunakan *chunk overlap* sebesar **100 karakter**. Overlap berfungsi untuk menjaga kesinambungan informasi antar *chunk*. Dengan adanya overlap, sebagian isi *chunk* sebelumnya akan ikut dimasukkan ke *chunk* berikutnya sehingga informasi yang berada di batas dua *chunk* tidak hilang. Hal ini meningkatkan peluang sistem menemukan konteks yang lebih lengkap saat proses retrieval.

C. Analisis Hasil: Baseline vs RAG

Pertanyaan : Apa itu CRISP-DM?

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
Konten	Gemini memberikan penjelasan umum mengenai CRISP-DM berdasarkan pengetahuan yang dimiliki model	Gemini menjelaskan CRISP-DM berdasarkan informasi yang diambil dari dokumen PDF melalui proses retrieval.
Kebenaran	Benar secara umum, namun tidak mengacu langsung pada dokumen yang digunakan.	Benar dan sesuai dengan isi dokumen PDF yang menjadi sumber informasi.

Analisis Kritis :

Pada pengujian tanpa RAG, model memberikan jawaban berdasarkan pengetahuan umum yang dimiliki sehingga belum tentu sama dengan isi dokumen PDF. Setelah menggunakan RAG, sistem terlebih dahulu mengambil potongan dokumen yang paling relevan menggunakan FAISS, kemudian menjadikannya sebagai konteks bagi Gemini. Hasilnya, jawaban menjadi lebih sesuai dengan isi dokumen dan lebih akurat. Meskipun demikian, apabila informasi yang dicari tidak terdapat di dalam dokumen, sistem akan memberikan jawaban bahwa informasi tersebut tidak ditemukan sehingga risiko hallucination dapat dikurangi.

D. Eksplorasi Relevansi (Top-K)

Nilai K yang dicoba :


- K = 3
- K = 5

Dampak :

Pada nilai **k = 3**, sistem mengambil tiga *chunk* yang paling relevan sehingga jawaban yang dihasilkan lebih fokus terhadap pertanyaan pengguna.

Pada nilai **k = 5**, sistem memperoleh konteks yang lebih banyak. Namun, beberapa *chunk* tambahan tidak selalu relevan sehingga jawaban menjadi lebih panjang dan terkadang kurang fokus. Berdasarkan hasil pengujian, nilai **k = 3** memberikan keseimbangan terbaik antara relevansi dan efisiensi untuk dokumen yang digunakan.

E. Dokumentasi Weights & Biases (W&B)



F. Kesimpulan & Refleksi

1. Apa kendala terbesar Anda saat menghubungkan dokumen PDF ke dalam model AI? Kendala terbesar saya pada saat implementasi ini adalah memastikan dokumen PDF dapat diproses dengan baik menjadi *chunk* yang sesuai untuk proses embedding dan retrieval. Selain itu, proses integrasi antara Gemini API, FAISS, SentenceTransformer, dan Weights & Biases memerlukan penyesuaian kode agar seluruh komponen dapat berjalan dengan baik. Penggunaan Gemini API versi gratis juga memiliki batas kuota (*rate limit*) sehingga jumlah pengujian harus disesuaikan.

2. Bagaimana teknologi RAG ini dapat diimplementasikan untuk membantu mahasiswa di kampus dalam mencari informasi akademik? Teknologi RAG dapat diterapkan sebagai asisten akademik yang mampu menjawab pertanyaan berdasarkan dokumen kampus, seperti buku pedoman akademik, modul perkuliahan, jurnal, skripsi, maupun peraturan akademik. Dengan memanfaatkan RAG, mahasiswa tidak perlu membaca seluruh dokumen secara manual karena sistem akan mencari informasi yang paling relevan dan memberikan jawaban berdasarkan isi dokumen tersebut. Hal ini membuat proses pencarian informasi menjadi lebih cepat, efisien, dan akurat.