

Informasi Mahasiswa :

- Nama : Mush'ab Abdurrahman Fathin
- NIM : 2411070062
- Link W&B Project: <https://wandb.ai/mushab-a-fathin-stikomelrahma/rag-gemini-vs-pure-ai/>
- Link Repositori Proyek : <https://github.com/MAF243/RAG>

1. Konsep Large Language Models (LLM)

Jelaskan dengan bahasa Anda sendiri:

1. Apa yang dimaksud dengan fenomena "Hallucination" pada AI dan mengapa hal itu terjadi?
2. Bagaimana mekanisme "Retrieval-Augmented Generation (RAG)" mampu menutupi kelemahan LLM dalam hal data yang bersifat privat atau terbaru?

Jawaban :

1. Halusinasi pada AI adalah kondisi di mana model memberikan jawaban yang terdengar sangat meyakinkan dan percaya diri, padahal informasi tersebut salah, mengarang, atau tidak berdasar. Hal ini terjadi karena LLM pada dasarnya adalah mesin penebak kata (berbasis statistik probabilitas), bukan basis data fakta. Jika ia tidak memiliki pengetahuan yang cukup tentang suatu topik, ia akan merangkai kata-kata yang secara tata bahasa masuk akal, meskipun faktanya keliru.
2. RAG menutupi kelemahan ini dengan memberikan "buku catatan" sebelum AI menjawab. Saat ada pertanyaan, sistem (Retriever) akan mencari potongan dokumen privat/terbaru yang paling relevan dari *database* vektor. Potongan teks tersebut kemudian disisipkan ke dalam *prompt* (konteks). LLM (Generator) kemudian diperintahkan secara ketat untuk hanya menjawab berdasarkan konteks yang disisipkan tersebut, sehingga AI tidak perlu menebak-nebak dari ingatan bawaannya.

2. Eksperimen Preprocessing (Chunking Strategy)

Dalam RAG, dokumen harus dipecah menjadi potongan kecil. Jelaskan pengaruh parameter berikut terhadap kualitas jawaban AI:

1. **Chunk Size** : Apa yang terjadi jika ukuran chunk terlalu besar atau terlalu kecil?
2. **Chunk Overlap** : Mengapa kita membutuhkan overlap antar potongan teks?

Jawaban :

1.
 - **Terlalu kecil:** Konteks kalimat akan terputus. AI mungkin kehilangan inti informasi penting (misal: subjek ada di *chunk* pertama, tapi predikatnya ada di *chunk* kedua), sehingga jawaban menjadi tidak akurat atau AI gagal memahami teks.
 - **Terlalu besar:** Membawa terlalu banyak informasi yang tidak relevan (teks menjadi berisik/ *noisy*). Ini bisa membuat AI kebingungan fokus pada inti pertanyaan, serta memboroskan kuota token batas maksimal *prompt* LLM.
2. *Overlap* (irisan) berfungsi sebagai "perekat" antar potongan. Saat teks dipotong secara kaku (misalnya tepat di tengah paragraf atau kalimat penting), *overlap* memastikan bahwa beberapa kalimat di akhir *chunk* pertama diulang di awal *chunk* kedua. Ini menjaga agar tidak ada konteks penting yang terpotong dan hilang.

3. Analisis Hasil: Baseline vs RAG

Tuliskan perbandingan jawaban AI untuk pertanyaan yang sama berdasarkan file PDF yang Anda gunakan.

Pertanyaan: Apa fungsi Akal??

Kategori	Jawaban Model (Tanpa RAG)	Jawaban Model (Dengan RAG)
Konten	Akal adalah salah satu anugerah terbesar bagi manusia, sebuah fakultas mental yang memungkinkan kita untuk berpikir, memahami, menganalisis, dan membuat keputusan. Fungsi akal sangat fundamental dan luas, mencakup berbagai aspek kehidupan manusia. Berikut adalah fungsi-fungsi utama akal: 1. Memahami dan Memproses Informasi: Akal memungkinkan kita untuk menerima, mengolah, dan menafsirkan data yang masuk melalui indra. Ini termasuk kemampuan untuk menganalisis, mensintesis, mengabstraksi, dan menggeneralisasi informasi untuk membentuk konsep dan pengetahuan. 2. Pengambilan Keputusan dan Penalaran: Akal adalah dasar dari kemampuan kita untuk berpikir logis dan rasional. Kita menggunakan akal untuk menimbang berbagai pilihan, memprediksi konsekuensi, dan memilih tindakan yang paling tepat atau menguntungkan. Ini melibatkan penalaran deduktif dan induktif.	Berdasarkan konteks yang diberikan, fungsi Akal adalah kemampuan berfikir. Berfikir didefinisikan sebagai menghubungkan fakta yang terindra dengan informasi sebelumnya di dalam otak.

	3. Pemecahan Masalah: Ketika dihadapkan pada tantangan atau masalah, akal berfungsi untuk mengidentifikasi akar masalah, mencari berbagai solusi yang mungkin, mengevaluasi efektivitasnya, dan merencanakan langkah-langkah untuk mengatasinya. 4. Pembelajaran dan Adaptasi: Akal memungkinkan kita untuk belajar dari pengalaman, mengakumulasi pengetahuan, dan menyesuaikan diri dengan lingkungan atau situasi baru. Ini melibatkan memori, pemahaman, dan kemampuan untuk mengubah perilaku berdasarkan informasi baru. 5. Kreativitas dan Inovasi: Akal tidak hanya tentang logika, tetapi juga tentang kemampuan untuk menghasilkan ide-ide baru, menciptakan sesuatu yang orisinal, dan menemukan cara-cara baru untuk melakukan sesuatu. Ini adalah dasar dari seni, ilmu pengetahuan, dan teknologi. 6. Refleksi Diri dan Kesadaran: Akal memungkinkan manusia untuk merenungkan diri sendiri, memahami emosi, nilai-nilai, tujuan hidup, serta posisi mereka di dunia. Ini adalah dasar dari kesadaran diri, etika, dan moralitas.	
--	---	--

	7. Komunikasi dan Bahasa: Akal berperan penting dalam kemampuan kita untuk mengorganisir pikiran menjadi bahasa yang koheren, baik lisan maupun tulisan, serta memahami bahasa orang lain. 8. Mencari Kebenaran dan Makna: Akal mendorong manusia untuk bertanya tentang eksistensi, tujuan hidup, alam semesta, dan mencari kebenaran di balik fenomena. Ini adalah dasar dari filsafat, ilmu pengetahuan, dan pencarian spiritual. Singkatnya, akal adalah inti dari kemanusiaan kita. Tanpa akal, manusia tidak akan mampu berkembang, menciptakan peradaban, atau memahami dunia di sekitarnya. Akal memungkinkan kita untuk tidak hanya bertahan hidup, tetapi juga untuk berkembang dan mencapai potensi penuh kita. Oleh karena itu, mengembangkan dan menggunakan akal secara bijak adalah kunci untuk kehidupan yang bermakna dan kemajuan peradaban.	
Kebenaran	(Mengarang)	(Benar)

Analisis Kritis : Jelaskan perubahan kualitas jawaban yang Anda amati. Apakah AI masih mengalami halusinasi meskipun sudah diberi data pendukung?

Analisis Kritis:

Dari perbandingan di atas, terlihat perubahan perilaku yang sangat drastis pada model AI sebelum dan sesudah menggunakan RAG.

Pada pengujian **tanpa RAG (Baseline)**, model bertindak seolah-olah ia adalah "seorang filsuf". Ia memanggil pengetahuan umum bawaannya (*pre-trained knowledge*) dan menghasilkan esai panjang berisi 8 poin filosofis dan psikologis tentang akal. Meskipun secara umum penjabaran tersebut masuk akal, dalam konteks akademik pengujian ini, jawaban tersebut dikategorikan sebagai **halusinasi konteks (mengarang)**. AI gagal menangkap definisi spesifik yang dimaksud oleh penulis dokumen. Hal ini memicu masalah *over-generation* di mana AI memberikan terlalu banyak informasi (*noise*) yang tidak relevan dengan kebutuhan pengguna.

Sebaliknya, pada pengujian **dengan RAG**, model berubah peran menjadi "seorang pembaca dokumen yang patuh". AI menghentikan kebiasaannya berasumsi dan langsung mengekstrak definisi spesifik (harfiah) yang tertulis di dalam dokumen PDF. Ia berhasil mengidentifikasi bahwa dalam literatur tersebut, fungsi akal dikerucutkan pada definisi spesifik: *kemampuan berfikir melalui proses penghubungan fakta terindra dengan informasi di dalam otak*.

Hal ini membuktikan bahwa arsitektur RAG berhasil mengunci atau memberikan batasan (*grounding*) pada LLM. RAG memaksa model untuk memprioritaskan "Fakta Lokal" dari dokumen privat dibandingkan "Fakta Global" dari memori pelatihannya, sehingga jawaban yang dihasilkan menjadi sangat ringkas, padat, dan 100% akurat sesuai konteks yang diuji.

4. Eksplorasi Relevansi (Top-K)

Coba ubah nilai `k` (jumlah potongan dokumen yang diambil untuk satu pertanyaan).

- **Nilai K yang dicoba** : 3, 5, dan 10
- **Dampak:** Apakah mengambil lebih banyak dokumen selalu membuat jawaban AI lebih baik, atau justru membuatnya bingung?

Dampak: Mengambil lebih banyak dokumen (Top-K yang lebih tinggi seperti K=10) **tidak selalu** membuat jawaban lebih baik. Saat K disetel terlalu tinggi, sistem akan mengambil dokumen yang tingkat kemiripannya (relevansinya) rendah. Akibatnya, *prompt* dipenuhi dengan "sampah teks" (*noise*) yang tidak nyambung dengan pertanyaan. Ini justru membuat AI kebingungan mencari jawaban yang tepat (fenomena *Lost in the Middle*) dan memperlambat proses *response time*. Nilai K=3 hingga 5 terbukti menjadi titik ideal untuk keseimbangan akurasi dan efisiensi.

5. Dokumentasi Weights & Biases (W&B)

Lampirkan *screenshot* dari *dashboard* W&B Anda yang menampilkan log tabel perbandingan pertanyaan dan jawaban.

Mushab-a-fathin's workspacePersonal workspace

Saved just now

Runs

Search runs

3 filtersGroupSortNew sweep

NAME1 of 9 listed

PERTANYAAN

JAWABAN AI MURNI

JAWABAN AI RAG

ekspei...umen

Apa fungsi Akal?

Akal adalah salah satu anugerah terbesar bagi manusia, Berdasarkan konteks yang diberikan, fungsi Akal adalah **kemar

1-1 of 1

6. Kesimpulan & Refleksi

1. Apa kendala terbesar Anda saat menghubungkan dokumen PDF ke dalam model AI?
2. Bagaimana teknologi RAG ini dapat diimplementasikan untuk membantu mahasiswa di kampus dalam mencari informasi akademik?

Jawaban :

1. Kendala terbesar di lapangan adalah kualitas dan format data PDF yang tidak ideal. Saya menghadapi kasus di mana file PDF tidak berisi teks (*text layer*), melainkan sekumpulan gambar/hasil *scan*. Modul pembaca PDF standar (PyPDFLoader) tidak bisa mengekstrak apa pun. Saya harus mengimplementasikan teknik "Page Rendering" menggunakan *library* PyMuPDF untuk merender PDF menjadi gambar utuh, lalu menggunakan mesin RapidOCR untuk memindai dan membaca huruf-huruf di dalam gambar tersebut agar bisa dicerna oleh AI. Selain itu, ada tantangan adaptasi dengan *deprecation* versi LLM Google, di mana saya harus melakukan pembaruan ke model terbaru (gemini-2.5-flash).
2. RAG dapat diimplementasikan sebagai asisten *chatbot* kampus (*virtual akademik*). Semua dokumen pedoman akademik, modul mata kuliah, syarat kelulusan, jadwal, dan buku panduan UKT bisa diunggah ke *Vector Database*. Mahasiswa tidak perlu lagi membaca dokumen ratusan halaman secara manual. Mereka cukup bertanya kepada *chatbot* (misalnya: "Berapa batas SKS jika IPK saya 3.5?"), dan AI akan langsung memberikan jawaban akurat beserta sumber rujukannya (Halaman dan Bab pedoman terkait) secara instan, menyingkirkan risiko disinformasi.